



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 河南师范大学

参赛队号 24104760045

1.卢韶鹏

队员姓名 2.王志龙

3.张哲浩

中国研究生创新实践系列大赛

“华为杯”第二十一届中国研究生

数学建模竞赛

题 目： 数据驱动下磁性元件的磁芯损耗建模

摘 要：

磁芯损耗是影响磁性元件效率和性能的关键因素，其复杂性源于温度、频率、磁芯材料及励磁波形等多因素的共同作用，难以通过传统模型精确预测。近年来，基于数据驱动的磁芯损耗建模方法受到了广泛关注。通过利用实测数据，分析不同因素对磁芯损耗的影响，本研究构建了一个高精度的预测模型，能够在多种工况下实现损耗的准确估算。该模型为磁性元件的优化设计提供了有力支持，提升了功率变换器的效率和可靠性。

针对问题一： 首先对**数据预处理**，从附件中筛选出有效数据后，提取磁通密度分布和形状特征，进行标准化。通过 **Spearman 相关系数热力图** 展现了励磁波形、磁通密度分布与形状特征间的相关性，揭示了励磁波形与这些特征的内在关联。在分类任务中，**通过五种方案的对比**，最终决定了**随机森林算法**为最佳方案，同时使用交叉验证选取最优参数，对不同材料的励磁波形进行分类。

针对问题二： 对于磁性元件的磁芯损耗问题，传统的斯坦麦茨方程在一定条件下存在较大误差。本文通过引入**温度修正项**，首先构建**线性修正模型**，结果表明，在中低温条件下，修正方程较好地提升了损耗预测的精确度。然而，对于复杂温度场景和高温条件下，线性修正模型仍存在误差，因此进一步提出了**非线性温度修正模型**。该模型通过**智能进化遗传算法**进行参数优化，结果显示，非线性修正模型在广泛的工况下具有更高的预测准确度，**模型拟合优度达到 0.9952**，尤其在高温条件下，极大地改善了预测效果。

针对问题三： 为了分析温度、励磁波形和磁芯材料对磁芯损耗的独立及协同作用，我们首先对**单因素**进行了**方差分析 (ANOVA)** 对每个因素的独立影响进行评估，并通过 F 值和 P 值判断各因素的显著性。在此基础上，为了进一步**探讨各因素之间的协同作用**，进行了假设，在因素为线性条件下构建了**多元线性回归模型**，加入温度、材料、波形之间的交互项。此外，为了捕捉非线性关系，采用了**随机森林模型**，我们识别了各因素的特征重要性，通过**可视化**进一步验证了温度、材料和波形对损耗的显著影响，为寻找最佳组合提供了有力支持。最终，我们建立了基于**粒子群优化 (PSO)** 模型分析确定了磁芯损耗的**最优组合**。

针对问题四：目标是使用数据驱动的方式构造跨越不同材料类型与工况条件的磁芯损耗预测模型，首先，在问题一**数据预处理**的基础上，引入了第二问**修正斯坦麦茨方程**的构造，得到**修正后的磁芯损耗**，将其作为重要特征加入到训练集中。为了构建跨越不同材料类型与工况条件的磁芯损耗预测模型，我们选取了 5 种数据驱动模型，**建立了 3 种方案**，经过多角度筛选对比，最终选取了**多层感知机（MLP）**作为最终预测模型，在此基础上，又加入修正后的磁芯损耗列作为特征输入，模型预测**精度显著提升**。

针对问题五：为了寻找既最小磁芯损耗同时拥有最大传输磁能的最佳条件，首先对数据进行了**预处理**，然后我们基于第四问模型的基础上，加入了**粒子群优化算法**，构建一个综合的**多目标优化模型**，来对磁芯损耗和传输效率在温度、频率、波形、磁通密度峰值及磁芯材料因素的影响下进行优化。通过多次实验，我们发现未加任何物理约束的优化算法中，频率和磁通密度峰值总是趋向边界值，导致优化结果不具备实际指导意义。为此，我们参考了磁芯损耗的组成，在**优化过程中引入物理约束**，建立了**基于物理引导的粒子群优化**的优化模型，得到更平滑的误差曲线，最终找到在特定工作条件下的**最优解**。

关键词： 机器学习 协同作用分析 智能进化遗传算法 多元线性回归 基于物理引导的粒子群优化的优化模型

目录

一、 问题重述	4
1.1 问题背景	4
1.2 问题提出	4
二、 总技术路线图	5
三、 模型假设	6
四、 符号说明	6
五、 模型建立与求解	7
5.1 问题一模型建立与求解	7
5.1.1 问题一描述与分析	7
5.1.2 问题一模型建立	7
5.1.3 问题一模型求解与分析	9
5.1.4 问题一分类结果	14
5.2 问题二模型建立与求解	15
5.2.1 问题二描述与分析	15
5.2.2 问题二模型建立	15
5.2.3 问题二模型求解与分析	17
5.3 问题三模型建立与求解	22
5.3.1 问题三描述与分析	22
5.3.2 问题三模型建立	22
5.3.3 问题三模型求解与分析	25
5.3.1 问题三模型结果分析	30
5.4 问题四模型建立与求解	31
5.4.1 问题四描述与分析	31
5.4.2 问题四模型建立	32
5.4.3 问题四模型实验与分析	37
5.4.4 问题四预测结果	42
5.5 问题五模型建立与求解	43
5.5.1 问题五描述与分析	43
5.5.2 问题五模型建立	43
5.5.3 问题五模型求解与分析	44
5.5.4 问题五结果分析	46
六、 模型的评价与推广	48
6.1 模型的优点	48
6.2 模型的缺点	48
参考文献	49
附录	50

一、问题重述

1.1 问题背景

随着社会经济的发展和科技的进步，电力电子技术在电能变换领域得到了广泛应用，尤其是在新能源、通信电源、数据中心电源、电动汽车等领域。功率变换器作为电能变换的核心设备，追求更高的效率和更小的体积，而其中的磁性元件（如变压器和电感）是关键部件，其损耗特性直接影响功率变换器的整体性能。

磁性元件的损耗主要包括绕组损耗和磁芯损耗，其中绕组损耗可以通过电磁场仿真精确计算，而磁芯损耗则复杂得多。磁芯损耗由高频交变磁通作用下的磁性材料产生，受多种因素（如频率、磁通密度、温度和材料等）影响，表现出复杂的非线性特性。传统的磁芯损耗模型与实际应用需求存在较大差距，难以精确预测磁芯损耗，进而影响到功率变换器的设计优化。因此，建立一个基于数据驱动的高精度、广泛适用的磁芯损耗模型，对提升磁性元件的设计和优化至关重要。本研究旨在通过实测数据建立磁芯损耗模型，分析其损耗特性，并进行模型修正和优化，以满足不同工况下的实际应用需求。问题涉及以下几个关键方面：

1.励磁波形分类：问题要求利用实验数据，通过提取磁通密度的形状特征，建立分类模型识别不同励磁波形（正弦波、三角波、梯形波）。需分析分类模型的合理性与有效性，并对测试样本进行识别和统计，以理解波形对磁芯损耗的影响。

2.斯坦麦茨方程修正：传统的斯坦麦茨方程用于磁芯损耗计算，受限于特定条件（如正弦波、特定温度）。该问题要求构建一个修正方程，能适应不同温度变化，提高损耗预测的精度，并分析修正方程与原方程的误差和适用性。

3.磁芯损耗因素分析：通过实验数据分析温度、励磁波形、磁芯材料等因素对磁芯损耗的影响。需讨论这些因素的独立作用及其相互协同影响程度，并探索在何种条件下损耗最小化。

4.基于数据驱动的磁芯损耗预测模型：利用实验数据构建一个高精度、广泛适用的磁芯损耗预测模型。模型应具备良好的泛化能力，能跨越不同材料类型和工作条件，提升磁性元件设计的精准性，并预测测试样本的损耗。

5.磁性元件的最优化条件：建立优化模型，以同时考虑磁芯损耗和传输磁能（频率与磁通密度峰值的乘积）。分析在不同条件下（温度、频率、波形等）如何实现磁芯损耗最小和传输磁能最大化，为磁性元件的设计优化提供指导。

1.2 问题提出

问题一：励磁波形分类。鉴于不同励磁波形对磁芯损耗特性的影响显著，需要对励磁波形进行分类识别。通过分析磁通密度随时间变化的特征，提取形状特征变量，建立分类模型，准确识别正弦波、三角波和梯形波的励磁波形，为深入理解磁芯损耗机制提供数据支持。


问题二：斯坦麦茨方程修正。传统的斯坦麦茨方程在计算磁芯损耗时局限于特定条件，难以适应不同温度等复杂工况。为提高损耗预测精度，需要构造一种修正方程，能够适应多种温度变化条件，以更好地描述磁芯损耗特性，为工程应用提供更精确的计算工具。


问题三：磁芯损耗因素分析。磁芯损耗受多种因素影响，如温度、励磁波形和磁芯材料等。为优化磁性元件设计，需要分析这些因素如何独立或协同作用于磁芯损耗，探索各自的影响程度，并寻找最优条件以实现最低损耗，从而提高设备的效率和稳定性。

问题四：基于数据驱动的磁芯损耗预测模型。现有磁芯损耗模型在精度和适用性方面存在局限性，难以满足实际设计需求。为此，需要利用实测数据构建一个高精度的损耗预测模型，能够跨越不同材料和工作条件，实现更精确的损耗估计，提升磁性元件的设计与优化能力。

问题五：磁性元件的最优化条件。在磁性元件设计中，不仅要降低磁芯损耗，还要提高传输磁能（由频率与磁通密度峰值的乘积衡量）。需建立优化模型，综合考虑温度、频率、波形等条件，分析在何种工况下能够实现损耗最小化和传输磁能最大化，为磁性元件的优化设计提供理论依据。

二、总技术路线图





三、模型假设

- (1) 假设实验中的所有温度和频率数据都是准确的，且实验条件下磁芯材料的特性不会发生显著变化，确保这些数据可以直接用于斯坦麦茨方程的修正模型中。
- (2) 假设影响磁芯损耗的主要因素为温度、频率和磁通密度，忽略其他可能影响磁芯损耗的次要因素（如电流波形的高阶谐波等），以简化模型。
- (3) 假设同一磁芯材料的所有样本具有均匀的物理特性，不考虑材料内部的细微差异或材料制备过程中的变异对实验结果的影响。
- (4) 假设实验数据完整无缺，且各个实验条件下的数据都是充分的，从而无需进行复杂的数据补全或插值处理。
- (5) 假设实验使用的测量设备具有足够高的精度，能够准确测量磁芯损耗、温度和频率等参数，不会出现系统性的测量误差。

四、符号说明

表1 符号说明

符号	含义
f	频率
B_{max}	磁通密度的峰值

P_{loss}	磁芯损耗
MSE	均方误差
MAE	平均绝对误差
R^2	拟合优度
$\hat{y}$	模型的预测值
SSB	计算组间平方和
SSE	计算组内平方和
RMS	均方根值
crest_factor	峰值因子
$X_{interaction}$	温度和频率的交互项


五、模型建立与求解

5.1 问题一模型建立与求解

5.1.1 问题一描述与分析

在磁性元件的设计与优化中，励磁波形是影响磁芯损耗的关键因素之一。磁芯损耗的大小与励磁波形的形态密切相关[1]，不同波形直接影响磁通密度的动态变化，从而对磁芯的损耗特性产生显著影响。因此，准确识别并分类励磁波形是深入研究磁芯损耗机制的重要前提。问题一的主要任务是：对附件一中的训练集进行数据预处理，将励磁波形信息转换为数值化表示（1 表示正弦波，2 表示三角波，3 表示梯形波）。然后，通过提取磁通密度的分布特征和形状特征，建立分类模型以识别这三种波形。最后，将分类结果应用于附件二中的样本数据，并将结果填入附件四中对应的表格列中[2]。

5.1.2 问题一技术路线图



5.1.3 问题一模型建立

(1) 数据预处理

对附件 1 中的训练集进行数据预处理，将励磁波形信息转换为数字化表示（1 表示正弦波，2 表示三角波，3 表示梯形波），并对磁通密度数据进行分析。。

①励磁波形映射

将励磁波形按照以下规则转换为数值形式：

表2 励磁波形映射表

类型	映射
正弦波	1
三角波	2
梯形波	3

②材料标签合并

将附件一的每种材料对应的标签加入到数据中，并将不同材料的数据合并为一个大表。

③材料标签映射

将材料标签按如下规则映射为数值：

表3 材料标签映射表

磁芯材料	映射
材料 1	1
材料 2	2
材料 3	3
材料 4	4

④归一化处理

在分类模型构建过程中，为了消除不同特征量纲对模型训练的影响，需要对提取的特征进行归一化处理。归一化可以将数据缩放到同一个尺度范围内，从而提高模型的训练效果和分类精度。

将数据线性缩放到[0,1]的范围,公式如下：

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (1)$$

其中， X 为原始数据值，表示未归一化的原始特征值； $X_{\max}$ 为数据集中的最大值； $X_{\min}$ 为数据集中的最小值； X' 为归一化后的数据值，表示将原始数据转换到 0,1 之间的新值。

（2）特征提取

分布特征包括：均值（Mean）、标准差（Std）、最大值（Max）、最小值（Min）、峰峰值（Peak-to-Peak）和均方根值（RMS）；

形状特征包括：总能量（total_energy）、峰值因子（crest_factor）、偏度（Skewness）和峰度（Kurtosis）。

（3）分类模型构建

为了将原始磁通密度数据转换为可以输入到分类模型的特征集构建的模型如下：

$$y_{pred} = f \left(\begin{matrix} 'Mean', 'Std', 'Max', 'Min', 'Peak-to-Peak', 'RMS', \\ 'total_energy', 'crest_factor', 'Skewness', 'Kurtosis', \end{matrix} \right) \quad (2)$$

其中 f 为机器学习的分类器，使用多种机器学习算法（如随机森林、支持向量机、决策树等）进行模型构建和选择。

y_{pred} 是励磁波形的类别，输入的第一行是磁通密度的分布特征，依次是均值，方差，最大值，最小值，峰峰值，均方根，输入的第二行是磁通密度的形状特征，依次是总能量、峰值因子、偏度、峰度。

（3）分类评价指标

模型的评估指标包括：

- ① 分类准确率（Accuracy）：衡量分类结果与真实值的匹配程度。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

- ② 精确率（Precision）：正确预测的正类占有所有预测为正类的比率。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4)$$

- ③ 召回率（Recall）：正确预测的正类占有所有真实正类的比率。

$$\text{Recall} = \frac{TP}{TP + FN} \quad (5)$$

- ④ F1-分数（F1-score）：精确率与召回率的调和平均数，反映模型的平衡性。

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (6)$$

- ⑤ 训练时间（Time）：模型训练所耗费的时间，衡量模型的效率。

5.1.4 问题一模型求解与分析

（1）磁通密度特征分析

本节以材料 1 磁通密度特征图为例展示进行分析。




图 5-1 材料 1 的特征分布图

由图可知，Mean（均值）的分布集中在 0.4 到 0.6 之间，有较高的偏度，说明数据在该区间的集中度较高，部分数据点位于较低值范围。

Std（标准差）的分布集中在较高的区域，约 0.6 到 0.8，表明数据在这些范围内的波动性较大。

Max（最大值）的分布主要集中在 0.7 到 1.0 之间，显示数据中存在较高峰值的现象。

Min（最小值）的分布集中在较低范围，特别是接近 0.1 以下，表明数据中可能存在一些非常小的测量值或噪声。

Peak-to-Peak（峰峰值）的分布较为广泛，数据集中在 0.5 到 0.8 之间，表示数据中存在显著的峰谷差异。

RMS（均方根值）的分布显示较大波动，集中在中间的值区间，表明数据能量分布较为分散。

Total Energy（总能量）显示出多峰分布，说明数据能量在多个区间有较多出现，反映出数据中存在不同能量级别的组分。

Crest Factor（峰值因子）集中在中等值附近，表明数据的峰值与均方根值的比例适中，但也存在少数极高的峰值因子。

Skewness（偏度）的分布较为平坦，集中在 0.4 到 0.6 区间，这意味着大部分数据呈现出正偏或轻微偏斜的特征。

Kurtosis（峰度）峰度集中在较低值，显示数据没有太多极端值，分布相对平坦，说明没有明显的尖峰或重尾特征。

这些特征的分布展示了数据的整体特性，包括集中趋势、波动性及偏度等，对后续的数据建模、特征选择和异常检测都提供了有价值的信息[2]。这些分布可以帮助理解数据的主要特征及其在分类或预测任务中的潜在影响。




图 5-2 材料 1 的箱线图

箱线图展示了不同特征在三类标签下的分布差异。类别 2 的特征值在多个维度上表现出更大的波动性和离群点，这可能是分类模型区分该类别的重要依据。类别 1 和 3 则较为集中，特征分布较稳定。这种分析对理解数据特征在分类任务中的区分能力有重要帮助。




图 5-3 材料 1 的特征之间的相关性热力图

特征之间的相关性热力图，展示了各个特征之间的相关系数，数值范围从 -1 到 1，颜色从蓝色（负相关）到红色（正相关）。相关性强的特征对可以用于特征选择和数据建模中的分析与优化。

如图，特征相关性热力图显示了数据中各特征之间的相关关系，RMS 与总能量、峰峰值与最大值、标准差与均方根值等特征呈现强正相关，显示这些特征在趋势上高度相似；而标准差与峰度、最小值与最大值/峰峰值之间呈现强负相关，表明这些特征在不同方向上变化显著。中等相关的特征如均值与峰度、峰值因子与偏度也提供了有价值的互补信息，这些发现有助于特征选择与模型优化。




图 5-3 材料 1 特征的小提琴图

小提琴图展示了各特征在三类标签下的明显差异，类别 2 的特征分布较宽，表明数据的波动性和极值现象更为明显，这可能对模型的分类和特征提取有较大帮助。而类别 1 和 3 表现相对稳定，特征集中，变化较少。这些分布特征有助于理解数据在不同类别下的特性，优化分类模型。

通过对四种材料的分析，得出梯形波具有最强的波动性和能量释放，三角波则介于正弦波和梯形波之间，表现为中等波动性和能量，而正弦波则最为平稳、对称性强，波动性小。特征如 RMS、总能量、峰峰值和偏度等是区分这三种波形的重要依据。

(2) 模型选择

本文首先选择随机森林（RandomForest）、支持向量机（SVM）中的支持向量机分类器（Support Vector Classifier）、K-最近邻算法、梯度提升决策树（Gradient Boosting Decision Tree）和决策树（DecisionTree）等机器学习模型进行训练与比较，并使用交叉验证来评估模型的性能。

(3) 模型结果对比

表4 材料一分类结果表

Model	RandomForest	SVC	KNN	GBDT	DecisionTree
accuracy	1.00	0.77	1.00	1.00	1.00
precisioin	1.00	0.83	1.00	1.00	1.00

recall	1.00	0.74	1.00	1.00	1.00
F1-score	1.00	0.73	1.00	1.00	1.00
Time(s)	0.56	0.35	0.06	3.60	0.04

表5 材料二分类结果表

Model	RandomForest	SVC	KNN	GBDT	DecisionTree
accuracy	0.99	0.65	0.96	0.97	0.97
precisioion	0.99	0.63	0.96	0.96	0.97
recall	0.99	0.62	0.96	0.97	0.97
F1-score	0.99	0.62	0.96	0.97	0.97
time	0.80	0.35	0.06	3.57	0.04

表6 材料三分类结果表

Model	RandomForest	SVC	KNN	GBDT	DecisionTree
accuracy	0.99	0.79	0.97	0.97	0.98
precisioion	0.99	0.76	0.96	0.97	0.98
recall	0.98	0.76	0.96	0.97	0.97
F1-score	0.99	0.76	0.96	0.97	0.98
time	0.81	0.50	0.07	4.02	0.05

表7 材料四分类结果表

Model	RandomForest	SVC	KNN	GBDT	DecisionTree
accuracy	1.00	0.88	1.00	1.00	0.99
precisioion	1.00	0.88	1.00	1.00	0.99
recall	1.00	0.80	1.00	1.00	0.99
F1-score	1.00	0.82	1.00	1.00	0.99
time	0.49	0.15	0.05	2.99	0.03

在不同磁芯材料的分类任务中，Random Forest 展现了稳定的高精度和较强的泛化能力，是整体表现最优的模型；KNN 在某些材料上表现出色，尤其在时间效率方面优势明显；Decision Tree 虽时间最短但易过拟合；GBDT 精确但计算成本高；而 SVC 整体表现较弱，尤其在复杂分类任务中不推荐使用。因此，Random Forest 是推荐的首选模型，KNN 和 Decision Tree 可作为特定场景的备选方案。

5.1.5 问题一分类结果

附件二中波形的数量统计如表 8 所示。

表8 附件二中波形的数量统计表

类型	数量
正弦波	26
三角波	43
梯形波	11

附件二中特定样本的分类结果如表 9 所示。

表9 附件二中波形的数量统计表


序号	类型
1	三角波
5	三角波
15	正弦波
25	正弦波
35	梯形波
45	梯形波
55	三角波
65	三角波
75	正弦波
80	正弦波

5.2 问题二模型建立与求解

5.2.1 问题二描述与分析

斯坦麦茨方程（Steinmetz-equation）是经典的磁芯损耗模型，主要针对正弦波形设计，适用于特定的磁芯材料和工作温度。在工程应用中，传统的斯坦麦茨方程因无法适应不同温度变化和非正弦波形，导致较大的预测误差。因此，本问题的目标是通过引入温度因素，构造一种修正方程以改进斯坦麦茨方程的预测效果，并在材料 1 数据的正弦波形下验证修正效果。

5.2.2 问题二技术路线图



5.2.3 问题二模型建立

（1）数据预处理

首先，读取数据从附件中读取数据，提取材料 1 的正弦波形数据。数据列包括温度、频率、磁芯损耗和磁通密度。

然后，基于孤立森林(Isolation Forest)算法进行异常值检测与处理，异常值（离群点）是数据中显著偏离大多数数据的点，这些点可能由于测量误差、设备故障或极端环境条件引起。异常值会对模型拟合产生较大干扰，导致预测结果不准确。因此，需要对这些异常值进行检测和处理。

① 构建孤立树（Isolation Trees），每个树 T_i 通过随机分割特征空间来孤立样本。

② 异常分数计算：

$$s(x, n) = 2^{\frac{E(h(x))}{c(n)}} \quad (7)$$

其中, $h(x)$ 是孤立树对样本 x 的分割深度, $E(h(x))$ 是样本 x 的平均分割深度, $c(n)$ 是一个归一化因子, 取决于样本数量 n 。

样本的异常分数 $s(x, n)$ 越接近 1, 样本越可能是异常值。

接着, 进行特征标准化。通过标准化消除不同特征之间的尺度差异, 提高模型拟合的稳定性和收敛速度。标准化的公式如下:

$$X' = \frac{X - \mu}{\sigma} \quad (8)$$

其中, X 是原始特征值, μ 是特征的均值, σ 是特征的标准差。

(2) 分析斯坦麦茨方程 (Steinmetz Equation, SE)

SE 方程的形式为:

$$P_c = k \cdot f^\alpha \cdot B_{max}^\beta \quad (9)$$

其中, P_c 是磁芯损耗, f 是频率, B_{max} 是磁通密度峰值, k 、 α 和 β 是通过实验拟合得到的系数。

SE 方程忽略了温度对磁芯材料的影响, 而温度会改变磁性材料的内部特性, 导致损耗的变化。温度影响损耗的原因主要包括磁芯材料的电阻率变化和磁畴运动的改变, 这些会影响磁滞损耗和涡流损耗的计算。

(3) 构造温度修正的斯坦麦茨方程

方案一: 线性温度修正方程

为适应温度变化的影响, 我们在原方程中引入一个温度修正因子 $T_c(T)$, 使得方程能够适应不同温度变化:

$$P_c = k \cdot f^\alpha \cdot B_{max}^\beta \cdot T_c(T) \quad (10)$$

其中, $T_c(T)$ 温度修正系数, 可以假设其形式为 $T_c(T) = a \cdot T + b$, 其中, T 是温度, a 和 b 是待拟合的参数。该修正系数可以通过实验数据拟合得到, 反映温度对磁芯损耗的影响。

线性温度修正方程理论基础:

材料电阻率随温度的变化: 随着温度的升高, 磁芯材料的电阻率通常会增加, 这会直接影响涡流损耗。由于电阻率的变化通常表现为线性的关系, 故引入一个线性的温度修正因子, 反映温度对损耗的线性影响[2]。

磁畴运动与磁滞损耗: 温度升高会加剧磁畴壁的移动, 导致磁滞损耗增加。由于磁滞损耗的变化可以表现为线性增长, 在低温区, 这种线性关系能够较好地描述温度对损耗的影响[4]。

方案二: 非线性温度修正方程

① 构造特征交互项

特征交互项的构建是为了引入特征之间的相互影响关系, 特别是在非线性模型中, 交互项能够增强模型的表达能力, 捕捉更复杂的特征间关系。在本问题中, 温度与频率之间的交互项可能反映更复杂的非线性影响关系, 因此引入这个交互项以提升模型的拟合效果。

$$X_{interaction} = X_{temperature} * X_{frequency} \quad (11)$$

其中, $X_{temperature}$ 是标准化后的温度特征, $X_{frequency}$ 是标准化后的频率特征, $X_{interaction}$ 是温度和频率的交互项。

② 构造温度修正的斯坦麦茨方程

$$P = k \cdot (f^\alpha) \cdot (B_{\max}^\beta) \cdot \exp(\gamma \cdot T + \delta \cdot T^2 + \eta \cdot X_{\text{interaction}}) \quad (12)$$

其中， γ 是线性温度修正系数，反映温度对损耗的直接影响。 δ 为二次温度修正系数，用于捕捉温度的非线性效应。 η 为交互修正系数，反映温度与其他变量的交互效应。

非线性温度修正方程理论基础

温度影响磁性材料微观结构的变化：随温度升高，磁畴的运动特性变得复杂，尤其是在高频激励下，涡流损耗和磁滞损耗的非线性增长更加显著。因此，考虑到温度和频率之间的交互作用，能够捕捉到更为复杂的损耗变化。

非线性效应的增强：温度和频率的结合可能会加剧损耗的非线性效应。例如，在高温高频条件下，损耗的增长速率会加快，因此需要通过非线性项来捕捉这一加速现象。

二次项对温度效应的提升：随着温度增加，材料特性（如磁滞损耗和涡流损耗）的变化通常并非严格线性，尤其是在高温下，可能呈现加速变化趋势。二次项 T^2 可以更好地捕捉温度对损耗的非线性影响。**错误!未找到引用源。**

交互项反映多因素耦合效应：交互项 $T \cdot X_{\text{interaction}}$ 捕捉了温度与频率的耦合效应，能够更精确地描述在高频高温条件下的损耗行为。

③ 模型评估指标

为了评估模型的性能，可以使用以下指标：

均方误差(Mean Squared Error,MSE):

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (P_{c,\text{实际}} - P_{c,\text{预测}})^2 \quad (13)$$

平均绝对误差(MeanAbsoluteError,MAE):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |P_{c,\text{实际}} - P_{c,\text{预测}}| \quad (14)$$

拟合优度(R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^n (P_{\text{实际},i} - P_{\text{预测},i})^2}{\sum_{i=1}^n (P_{\text{实际},i} - \bar{P}_{\text{实际}})^2} \quad (15)$$

其中， $P_{\text{实际},i}$ 是第 i 个观测值的实际值； $P_{\text{预测},i}$ 是第 i 个观测值的模型预测值； $\bar{P}_{\text{实际}}$ 是实际值的平均值。

高拟合优度（接近 1）：说明模型能较好地解释数据的变异，适合用来预测。

低拟合优度（接近 0）：说明模型未能很好地解释因变量的变异，可能存在欠拟合或模型不合适的情况。

负拟合优度：模型错误或者变量选择不当，建议进一步检验和优化模型。

5.2.4 问题二模型求解与分析

① 原始斯坦麦茨方程的拟合

对于 $P_c = k \cdot f^\alpha \cdot B_{\max}^\beta$ ，为了便于线性拟合，通常假设 $\beta = 1$ ，将方程线性化：

$$\log\left(\frac{P_c}{B_{\max}}\right) = \log(k) + \alpha \log(f) \quad (16)$$

首先，将获得预处理后的数据，计算 $\log(f)$ 和 $\log\left(\frac{P_c}{B_{\max}}\right)$ 。

接着，使用 Ridge 回归（带正则化的线性回归）来拟合线性化后的方程，防止过拟合。自变量 X 为 $\log(f)$ ，因变量 Y 为 $\log\left(\frac{P_\varepsilon}{B_{\max}}\right)$ 。其中，拟合结果的系数即为 α ，截距的指数值为 k （即 $\log(f)$ 的指数部分）。

结果分析：

$$R^2 = 0.068 \quad (17)$$

$$\text{MSE} = 13565349026.7947 \quad (18)$$

$$\text{MAE} \approx 56379.6502 \quad (19)$$

原始斯坦麦茨方程因其简单明了的结构和广泛的应用性，在基础磁芯损耗预测中具有一定的价值，但其缺点也十分明显。该方程未能充分考虑温度因素的影响，导致在高温极端条件下表现出较大的预测偏差，无法准确反映实际损耗的非线性变化。数值指标（如高 MSE、低 R^2 值）也表明该模型的预测精度较低。

因此，尽管原始斯坦麦茨方程在简单工况下可作为初步估算工具，但在复杂条件下需要通过非线性修正和温度效应的引入来显著提高其预测能力和实用性。

② 线性温度修正方程的拟合

对于 $P_c = k \cdot f^\alpha \cdot B_{\max}^\beta \cdot T_c(T)$ 即 $P_c = k \cdot f^\alpha \cdot B_{\max}^\beta \cdot (a \cdot T + b)$ ，使用贝叶斯优化，核心在于智能化地寻找最优参数，使得修正后的损耗预测误差最小。

优化目标函数：

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (P_{c,\text{实际}} - P_{c,\text{预测}})^2 \quad (20)$$

贝叶斯优化通过代理模型预测 a 和 b 的最佳组合，使得优化过程不需要大量的参数搜索，且更容易找到全局最优解。

结果分析：

$$R^2 = -0.2223 \quad (21)$$

$$\text{MSE} = 17691729754.4367 \quad (22)$$

$$\text{MAE} \approx 76329.6450 \quad (23)$$

线性修正斯坦麦茨方程的磁芯损耗预测对比图和线性修正斯坦麦茨方程的实际与预测损耗对比图如下所示，通过对比两幅图可以详细看出原始斯坦麦茨方程和修正后的方程在损耗预测上的表现差异。

原始斯坦麦茨方程（红色散点）在实际损耗高时表现出严重的系统性低估，尤其在高温和高损耗区域，几乎无视了实际变化，预测结果始终偏低。这主要是因为原始方程只考虑了频率和磁通密度的影响，忽略了温度的非线性效应和各因素之间的复杂交互。

修正后的斯坦麦茨方程（绿色散点和实线）通过引入温度修正项显著提升了模型的预测性能，在中低损耗和较高温度条件下更加贴近实际值，尤其在温度变化显著时，表现出对损耗更敏感的反应。然而，修正后的模型在极端高损耗区间仍有明显偏差，绿色散点在理想预测线之下散落较远，表明即使是增加了温度修正，模型在复杂条件下的非线性捕捉能力仍然不足。




图 5-4 线性修正斯坦麦茨方程的磁芯损耗预测对比




图 5-5 线性修正斯坦麦茨方程的实际与预测损耗对比图

③ 非线性温度修正方程的拟合

遗传算法可以用于优化拟合的参数，从而提高模型的预测精度。对于 $P = k \cdot (f^\alpha) \cdot (B_{\max}^\beta) \cdot \exp(\gamma \cdot T + \delta \cdot T^2 + \eta \cdot X_{\text{interaction}})$ ，本文使用智能进化遗传算法 (Intelligent Evolutionary Genetic Algorithm, IGAE)，通过动态调整交叉和变异率、引入多变异策略、精英保留、适应性选择和局部搜索增强等机制，提升遗传算法的全局优化能力和收敛速度。相比传统遗传算法，IGAE 在保持种群多样性和防止过早收敛方面表现更为优异，能够在复杂和多维的优化问题中更加精确和高效地寻找最优解。

步骤 1: **种群初始化**: 随机生成初始种群，其中每个个体由参数 $k, \alpha, \beta, \gamma, \delta, \eta$ 组成。

步骤 2: **适应度计算**: 使用非线性温度修正方程的误差 (MSE) 作为适应度函数，评估每个个体的好坏。

步骤 3: **自适应选择**: 根据适应度值选择个体进入下一代, 使用自适应选择策略来保持种群的多样性。

步骤 4: **交叉与变异**: 根据动态调整的交叉率和多变异策略, 生成新个体, 并应用精英保留策略。

步骤 5: **局部搜索**: 在进化的后期, 可结合局部优化算法对当前最优解进行微调, 以进一步降低误差。

步骤 6: **终止条件**: 当适应度值不再显著变化或达到最大迭代次数时, 停止进化。




图 5-5 改进的遗传算法流程图

结果分析:

$$R^2 = 0.9952 \quad (24)$$

$$\text{MSE} = 70012194.4132 \quad (25)$$

$$\text{MAE} \approx 5021.2830 \quad (26)$$

从数值结果来看, 非线性修正方程在捕捉实际损耗方面表现非常优越, 几乎完全贴合实际数据。这显示出修正方程在复杂工况下大幅提升了预测能力。




图 5-6 非线性修正斯坦麦茨方程的磁芯损耗预测对比




图 5-7 非线性修正斯坦麦茨方程的实际与预测损耗对比图

上述两幅图对比了原始斯坦麦茨方程和修正后的斯坦麦茨方程在磁芯损耗预测中的表现，展示了修正模型在考虑温度和交互项后对实际损耗的预测改进。第一幅图的散点对比表明，原始方程在高损耗区间严重低估了实际值，而修正方程显著改善了预测准确度，更接近理想预测线。第二幅图展示了在不同温度下的损耗变化，修正后的方程通过引入温度效应，尤其是在高温下，更好地捕捉到了实际损耗的波动趋势。

④ 线性温度修正方程和非线性温度修正方程对比分析

非线性修正相较于线性修正，在捕捉温度、频率及其他交互效应对磁芯损耗的影响上表现更为出色。非线性修正的引入使得模型对高温、高频等复杂工况的响应更为灵敏，有效减少了预测误差。

在实验结果中，非线性修正模型的拟合效果明显优于线性修正，表现为更接近实际损耗值的预测，尤其在高损耗和极端温度条件下尤为明显。这表明对于复杂的磁芯损耗


问题，非线性修正是比线性修正更优的选择，为后续磁性材料的损耗建模和工程应用提供了更可靠的理论支撑。

5.3 问题三模型建立与求解

5.3.1 问题三描述与分析

磁芯损耗是磁性元件设计中的关键指标，直接影响设备的性能与稳定性。影响磁芯损耗的主要因素包括温度、励磁波形和磁芯材料，这些变量通过复杂的物理机制相互作用。不同温度条件会改变磁芯材料的磁性特性，波形影响其磁化率，而材料本身的属性决定其对外界磁场的响应。为了降低磁芯损耗并优化磁性元件性能，本问题的目标是通过实验数据分析，量化这三个因素的独立和协同作用，进而找出使磁芯损耗最小的最优组合。由于存在非线性关系和复杂交互，传统线性分析方法难以处理，因此需要借助优化算法进行全局搜索与求解。

5.3.2 问题三技术路线图



5.3.3 问题三模型建立

(1) 数据预处理

由于问题三只要求分析温度、励磁波形和磁芯材、三者对磁芯损耗的独立和协同作用，并特别关注它们两两之间的交互影响，因此我们对附件一中的数据进行了筛选处理。首先，将 4 个 sheet（“材料 1”、“材料 2”、“材料 3”、“材料 4”）合并为一个数据集，同时只保留温度、励磁波形、磁芯材料和磁芯损耗这 4 项关键变量，生成最终文件“合并数据集.xlsx”。

表10 预处理后表

温度	磁芯材料	励磁波形	平均磁芯损耗	磁芯损耗方差
25	材料 1	三角波	278741.22	2.80e+11
25	材料 1	梯形波	253270.30	1.61e+11
25	材料 1	正弦波	133503.36	4.46e+10
25	材料 2	三角波	415553.84	3.45e+11
25	材料 2	梯形波	355257.74	2.78e+11
25	材料 2	正弦波	111256.32	2.83e+10
25	材料 3	三角波	387235.46	3.57e+11
25	材料 3	梯形波	419505.99	4.00e+11
25	材料 3	正弦波	128955.31	3.94e+10
25	材料 4	三角波	153636.27	8.91e+10
25	材料 4	梯形波	229097.56	9.32e+10
25	材料 4	正弦波	48728.83	4.90e+09
50	材料 1	三角波	234925.96	1.72e+11
50	材料 1	梯形波	197642.72	9.93e+10
50	材料 1	正弦波	101899.68	3.19e+10
50	材料 2	三角波	328612.66	2.51e+11
50	材料 2	梯形波	307549.74	2.45e+11
50	材料 2	正弦波	104904.67	2.52e+10
50	材料 3	三角波	336952.48	2.72e+11
50	材料 3	梯形波	353424.05	2.99e+11
50	材料 3	正弦波	103356.25	2.72e+10
50	材料 4	三角波	130724.68	5.11e+10
50	材料 4	梯形波	144309.81	5.60e+10
50	材料 4	正弦波	46663.65	5.11e+09
70	材料 1	三角波	197093.49	1.14e+11
70	材料 1	梯形波	169289.50	7.75e+10
70	材料 1	正弦波	88388.42	2.28e+10
70	材料 2	三角波	293533.75	1.88e+11
70	材料 2	梯形波	249337.24	1.66e+11
70	材料 2	正弦波	80530.46	1.78e+10
70	材料 3	三角波	305269.93	2.36e+11
70	材料 3	梯形波	323474.82	2.46e+11
70	材料 3	正弦波	74524.83	1.67e+10
70	材料 4	三角波	142064.10	6.41e+10
70	材料 4	梯形波	118329.19	4.29e+10
70	材料 4	正弦波	40432.67	3.84e+09
90	材料 1	三角波	201774.55	1.49e+11
90	材料 1	梯形波	162811.76	7.12e+10
90	材料 1	正弦波	83048.34	1.84e+10
90	材料 2	三角波	307709.75	2.13e+11
90	材料 2	梯形波	257622.89	1.66e+11
90	材料 2	正弦波	75470.76	1.48e+10
90	材料 3	三角波	288299.52	2.38e+11

90	材料 3	梯形波	294517.46	2.30e+11
90	材料 3	正弦波	97629.33	2.37e+10
90	材料 4	三角波	134766.14	5.11e+10
90	材料 4	梯形波	102800.55	3.01e+10
90	材料 4	正弦波	37860.13	2.79e+09

表11 各因素统计表

因素分布	样本个数
磁芯材料 1	3155
磁芯材料 2	2942
磁芯材料 3	3177
磁芯材料 4	2706..
正弦波	4948
三角波	4054
梯形波	3398
温度 25°	3244
温度 50°	3070
温度 70°	3030
温度 90°	3056

(2) 模型评价指标

针对磁芯损耗的分析与预测，我们可以使用以下评价指标来评估模型的性能。这些指标能衡量模型在预测磁芯损耗时的准确性和可靠性，以下是考虑这些因素后的评价指标：

① 计算组间平方和（SSB）：

衡量不同温度组之间的差异。公式为：

$$SSB = \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2 \quad (27)$$

其中， $\bar{y}_i$ 是第 i 组（对应某个温度）的磁芯损耗均值； $\bar{y}$ 是所有样本的总体均值； n_i 是第 i 组的样本数量； k 是温度的不同组数。

② 计算组内平方和（SSE）：

衡量每个温度组内的磁芯损耗差异，反映随机误差。公式为：

$$SSE = \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2 \quad (28)$$

其中， y_{ij} 是第 i 组中第 j 个样本的磁芯损耗值。

③ 计算 F 值：

$$F = \frac{\frac{SSB}{k-1}}{\frac{SSE}{N-k}} \quad (29)$$

其中， N 为总样本数量， k 为温度组数。

5.3.4 问题三模型求解与分析

(1) 对单元素影响磁芯损耗的分析

因为问题三要求是如何独立及协同影响着磁芯损耗，故采用了方差分析(ANOVA)[5] 去观察温度、励磁波形、磁芯材料对磁芯损耗的独立影响，及其影响程度。

选择 ANOVA 来分析单因素对磁芯损耗的影响，主要是因为它能够有效判断不同组别（如不同温度、材料、励磁波形）对目标变量（磁芯损耗）是否存在显著影响。ANOVA 通过比较组内和组间的方差，评估因素对响应变量的影响大小，从而识别不同组别之间的均值是否显著不同。

① ANOVA 原理介绍

选择 ANOVA 来分析单因素对磁芯损耗的影响，主要是因为它能够有效判断不同组别（如不同温度、材料、励磁波形）对目标变量（磁芯损耗）是否存在显著影响。ANOVA 通过比较组内和组间的方差，评估因素对响应变量的影响大小，从而识别不同组别之间的均值是否显著不同。

ANOVA 的基本思路是将数据的总变异拆解为两部分：

第一，组间方差：表示不同组（如不同温度、波形、材料）的均值之间的差异，反映自变量对因变量的影响。

第二，组内方差：表示每组内部的个体差异，反映噪声或随机误差。

通过比较组间方差与组内方差的比值，我们可以评估自变量是否对因变量有显著影响。如果组间方差显著大于组内方差，则表明自变量对因变量的影响显著。

$$F = \frac{\text{组间方差}}{\text{组内方差}} \quad (30)$$

方差分析中的关键统计量是 **F** 值，其定义为组间方差与组内方差的比值，如果 **F** 值较大（对应 **P** 值较小），则表明不同组之间的均值差异显著，自变量对因变量有显著影响。

② 磁芯损耗公式

首先，磁芯损耗 P_{loss} 通常可以用以下的经验公式表示：

$$P_{\text{loss}} = k \cdot f^a \cdot B^b \cdot V \quad (31)$$

其中， f 是工作频率； B 是磁通密度； V 是磁芯的体积； k 、 a 、 b 是与材料相关的常数。

然而根据题目要求，目前我们需要分析温度(T)、励磁波形(W)、磁芯材料(M)对磁芯损耗(P_{loss})的影响，在这种情况下，我们将**温度**、**励磁波形**和**材料特性**引入模型中，分别进行单元素分析。

③ 温度影响的基本假设

温度 T 对磁芯损耗的影响可以体现在材料的性能变化上，尤其是磁导率和损耗系数随温度的变化而改变。设磁芯材料的损耗系数 $k(T)$ 是温度的函数，则磁芯损耗公式可以修正为：

$$P_{\text{loss}}(T) = k(T) \cdot f^a \cdot B^b \cdot V \quad (32)$$

对于许多材料来说，磁芯损耗随着温度升高而增加。因此，可以假设 $k(T)$ 是温度的增函数。例如，使用二次项来近似描述 $k(T)$ 的变化：

$$k(T) = k_0 + k_1 T + k_2 T^2 \quad (33)$$

因此，损耗公式为：

$$P_{\text{loss}}(T) = (k_0 + k_1 T + k_2 T^2) \cdot f^a \cdot B^b \cdot V \quad (34)$$

在温度分析中，我们可以通过实验数据拟合出 k_0, k_1, k_2 的值，得出温度与磁芯损耗的具体关系。

为了验证温度对磁芯损耗的显著性，我们引入方差分析。假设我们对不同温度（如 25°C, 50°C, 70°C, 90°C）下的损耗进行测量，通过 ANOVA 评估温度对损耗的影响。

为进一步展示不同因素对磁芯损耗的影响，代码分别绘制了小提琴图和箱形图。有助于分析不同因素下数据的集中趋势与离散程度




图 5-8 温度对磁芯损耗的效果图

随着温度的上升，磁芯损耗的分布范围逐渐增大。在低温（如 25° C）下，损耗较低且方差小，但随着温度升高（如 50° C、70° C、90° C），损耗波动加剧，特别是在高温 90° C 时，损耗的离散性显著增加，表明温度上升对损耗影响较大。

④ 励磁波形影响的基本假设

励磁波形 W 通过引入不同的谐波成分影响磁芯损耗，非正弦波会引发额外的高频成分，增加损耗。可以假设励磁波形对磁芯损耗的影响为：

$$H(W) = 1 + h_1 W + h_2 W^2 \quad (35)$$

从而损耗公式修正为：

$$P_{\text{loas}}(W) = k \cdot f^a \cdot B^b \cdot V \cdot (1 + h_1 W + h_2 W^2) \quad (36)$$




图 5-9 波形对磁芯损耗的效果图

不同励磁波形对磁芯损耗影响显著。三角波和梯形波的损耗明显高于正弦波，且波动较大。正弦波损耗较低且稳定，适用于低损耗场景，而三角波和梯形波易导致较高损耗及波动。

⑤ 磁芯材料影响的基本假设

材料特性 M 影响损耗系数 k ，不同的材料对磁场的响应不同，因此损耗会随材料变化。可以使用材料的损耗函数 $\gamma(M)$ 来修正公式：

$$P_{\text{loss}}(M) = k_{\text{ref}} \cdot \gamma(M) \cdot f^a \cdot B^b \cdot V \quad (37)$$




图 5-10 材料对磁芯损耗的效果图

不同材料对磁芯损耗影响明显。材料 1 和材料 3 的损耗较小且分布集中，材料 2 和材料 4 的损耗较大，尤其材料 2 波动显著，表明材料的选择对降低损耗至关重要。

表12 单因素对损耗的影响表

因素	SSB (组间平方和)	SSE (组内平方和)	F 值	P 值
磁芯材料	4.11e+13	1.71e+15	99.12	2.12e-63
温度	6.92e+12	1.75e+15	49.03	2.64e-12
励磁波形	7.52e+13	1.68e+15	277.33	1.49e-118

结论：

通过单因素 ANOVA 的分析，我们可以定量地评估温度、波形和材料对磁芯损耗的独立影响。以下是通过 ANOVA 的单元素分析所得结论：

温度影响：温度升高通常会显著增加磁芯损耗。

波形影响：非正弦波（如三角波和梯形波）会导致更高的损耗。

材料影响：材料特性显著影响磁芯损耗，不同材料的选择至关重要。

（2）对双元素影响磁芯损耗的分析

对于问题三，在分析单一元素对磁芯损耗的影响后，为了更深入地探讨温度、励磁波形和磁芯材料对磁芯损耗的协同作用，将进一步采用了多元线性回归模型[6] 和随机森林回归模型来分析两两因素间的交互影响。

多元线性回归模型通过加入交互项，能够量化不同因素在协同作用下对磁芯损耗的影响程度，并识别出显著的协同效应。可以明确了解每个变量（包括交互项）对目标变量（磁芯损耗）的直接线性影响。

故先使用 线性回归模型提供基线，然后随机森林提供更复杂的见解，使用随机森林可以挖掘出更多的复杂关系，并为后续寻找到损耗最小的组合做准备。

a. 双元素交互项的引入

为了量化双元素之间的协同效应，我们在基本的磁芯损耗公式中引入 **交互项**，即考虑温度 T 、励磁波形 W 和材料 M 之间的双因素相互作用。我们扩展之前的磁芯损耗模型为：

$$P_{\text{loss}} = k \cdot f^a \cdot B^b \cdot V \quad (38)$$

在前面的分析中，我们将温度、励磁波形和材料分别作为单独的影响因素引入该模型。现在，我们考虑双元素组合对损耗的影响，构建包含交互项的模型：

①多元线性回归模型

假设：温度、**磁芯材料**、励磁波形对磁芯损耗的影响是线性的。则采用多元线性回归模型

$$P_{\text{loss}} = \beta_0 + \beta_1 T + \beta_2 M + \beta_3 W + \beta_4 (T \times M) + \beta_5 (T \times W) + \beta_6 (M \times W) + \epsilon \quad (39)$$

其中， P_{loss} 为磁芯损耗， β_0 为截距； $\beta_1, \beta_2, \dots, \beta_6$ 为待估参数； $T \times M$ 、 $T \times W$ 、 $M \times W$ 分别为温度与材料、温度与波形、材料与波形的交互项； ϵ 为误差项。

温度与材料的交互作用

温度 T 对材料 M 的磁导率、损耗系数影响显著。在高温下，某些材料的损耗系数会显著升高，而在低温下，这种影响可能较小。因此，温度与材料的交互项 $T \times M$ 可以用于描述材料在不同温度下对磁芯损耗的影响。

该交互项的表达式为：

$$P_{\text{loss}}(T, M) = \beta_0 + \beta_1 T + \beta_2 M + \beta_4 (T \times M) + \epsilon \quad (40)$$

温度与波形的交互作用

励磁波形 W 会通过引入不同的谐波成分影响磁芯损耗，尤其在高温下，非正弦波形（如三角波和梯形波）产生的高次谐波损耗显著增加。温度与波形的交互项 $T \times W$ 用于描述在不同温度下，不同波形对损耗的影响。

该交互项的表达式为：

$$P_{\text{loss}}(T, W) = \beta_0 + \beta_1 T + \beta_3 W + \beta_5 (T \times W) + \epsilon \quad (41)$$

材料与波形的交互作用

不同材料对不同波形的响应也会有所不同。某些材料在处理非正弦波时的损耗较高，而另一些材料可能具有较好的谐波抑制能力，因此磁芯损耗较低。材料与波形的交互项 $M \times W$ 则用于描述不同材料在不同波形下对损耗的影响。

该交互项的表达式为：

$$P_{\text{loss}}(M, W) = \beta_0 + \beta_2 M + \beta_3 W + \beta_6 (M \times W) + \epsilon \quad (42)$$

②随机森林模型

上述模型假设了线性交互项，但在实际应用中，温度、材料和波形的组合对磁芯损耗的影响往往表现出 **非线性关系**。为此，我们可以采用 **随机森林模型** 来捕捉更复杂的非线性交互。

假设：温度、**磁芯材料**、励磁波形 对 磁芯损耗的影响是非线性的。则采用**随机森林模型**

$$y = f(T, M, W) + \epsilon \quad (43)$$

其中， T, M, W 分别代码温度、材料、波形； f 由随机森林迭代学习过程中学到，能够捕捉特征间复杂的非线性关系。




图 5-11 基于 SHAP 值的特征重要性分析图

基于 SHAP (SHapley Additive exPlanations) 值的特征重要性分析展示了不同特征对模型输出的影响及其方向，通过 SHAP 值分析，可以看到波形和材料是最重要的特征，分别对模型输出有负向和正向影响，而 温度 及其交互特征的影响则较为复杂，需结合特征值大小来分析其影响方向。




图 x 等高线图

这三个图展示了温度、磁芯材料编码和励磁波形编码之间的相互作用对某个响应变量（如损耗或能量）的影响。通过等高线的展示，可以看到当温度升高、磁芯材料编码较高或者励磁波形较复杂时，系统的损耗或者负面影响都会显著增加。该分析可以帮助我们理解在不同工作条件下，选择合适的材料和励磁波形组合如何优化系统性能。

总结：

温度对磁芯损耗的影响最为显著，高温条件下，磁芯损耗明显增加。因此，优化磁芯损耗时应重点考虑在低温条件下操作。

磁芯材料和励磁波形对损耗有协同作用。具体来说，材料编码为 2 和波形编码为正弦波时，在高温或较高温度条件下能有效减少磁芯损耗。

协同作用显著，不同材料和波形的组合能够显著影响磁芯损耗，适合的组合在高温时能够显著降低损耗。

(3) 对三元素影响磁芯损耗的分析

由 (1) 对三元素影响磁芯损耗的分析和 (2) 对三元素影响磁芯损耗的分析可知：

针对磁芯损耗的进一步优化，结合温度、磁芯材料、励磁波形三个因素的协同作用，使用了基于粒子群优化 (PSO) 算法的建模与求解方法，旨在寻找这三者组合下使得磁芯损耗最小的组合。以下是该部分的建模分析与步骤。

为了找到最优组合，我们引入了粒子群优化 (PSO) 算法。PSO 是一种基于群体智能的优化算法，通过模拟群体中的个体 (粒子) 不断调整自己的位置和速度来逼近全局最优解。

PSO 算法设计：

$$v_i^{t+1} = w \cdot v_i^t + c_1 \cdot r_1 \cdot (p_i^t - x_i^t) + c_2 \cdot r_2 \cdot (g^t - x_i^t) \quad (44)$$

其中， v_i^t 表示粒子速度， x_i^t 表示粒子位置， p_i^t 为粒子的历史最优位置， g^t 为全局最优位置， w 是惯性权重，控制粒子的速度变化， c_1 c_2 是加速因子，分别对应个体和全局的加速影响； r_1 ， r_2 是随机数，用于增强算法的随机性和全局搜索能力。

PSO 参数设定：

在本例中，设定如下参数：

温度 T：取值范围为 25° C 到 90° C；

材料 M：编码为 0-3，分别对应材料 1 到材料 4；

波形 W：编码为 0-2，分别对应正弦波、三角波和梯形波。

惯性权重 $w=0.8$ ：经过实验调优，该值在初期较大以增强全局搜索能力，在后期减小有助于收敛至最优解。

加速因子 $c_1=1.5, c_2=1.5$ ：这些值的选择确保粒子在个体和群体最优解之间保持适当平衡，避免陷入局部最优解。

粒子数量 $pop=40$ ：粒子数量的选择经过实验验证，在计算成本和算法效率之间达成平衡。

最大迭代次数 $max_iter=100$ ：通过多次实验，100 次迭代已经足够保证算法收敛至最优解。

5.3.1 问题三模型结果分析




图 5-12 不同温度、材料和波形组合下的磁芯损耗变化趋势图

如图，展示了不同温度、材料和波形组合下的磁芯损耗变化趋势。总体上，随着温度的升高，磁芯损耗逐渐减少，不同材料和波形组合对损耗的影响显著。其中，材料 1 和材料 2 的组合在不同波形下损耗较高，而材料 3 和材料 4 与特定波形（如波形 2）的组合表现出最低的损耗，且受温度变化影响较小。

同时考虑三个因素对磁芯损耗的独立及协同影响，故三因素的取值为：90 摄氏度、正弦波、材料 4。


5.4 问题四模型建立与求解

5.4.1 问题四描述与分析

磁芯损耗的传统预测模型在精度和适用范围上存在不足，尤其是在不同的材料类型和工作条件下，无法提供统一而精确的预测。随着电力电子技术的快速发展，亟需建立一个能够在多种材料和工况条件下都表现出高精度的磁芯损耗预测模型[7]。问题四要求基于附件一的实验数据，通过数据分析与建模技术，构建一个磁芯损耗预测模型，评估其预测精度和泛化能力，并对附件三中的样本进行磁芯损耗的预测。

本问题强调基于实验数据，通过机器学习和数据分析技术，建立一个数据驱动的磁芯损耗预测模型。实验数据包含温度、频率、励磁波形、磁通密度采样点等多维输入特征，这些因素对磁芯损耗的影响是复杂且非线性的，因此使用数据驱动的机器学习模型可以更好地捕捉这些复杂关系[8]。

5.4.2 问题四技术路线图



5.4.3 问题四模型建立

(1) 数据预处理

对附件 1 中的训练集进行数据预处理，将励磁波形信息转换为数字化表示（1 表示正弦波，2 表示三角波，3 表示梯形波），并对磁通密度数据进行分析。。

① 励磁波形映射

将励磁波形按照以下规则转换为数值形式：

表13 励磁波形映射表

类型	映射
正弦波	1
三角波	2
梯形波	3

② 材料标签合并

将附件一的每种材料对应的标签加入到数据中，并将不同材料的数据合并为一个表。

③ 材料标签映射

将材料标签按如下规则映射为数值：

表14 材料标签映射表

磁芯材料	映射
材料 1	1
材料 2	2
材料 3	3
材料 4	4

④ 归一化处理

在分类模型构建过程中，为了消除不同特征量纲对模型训练的影响，需要对提取的特征进行归一化处理。归一化可以将数据缩放到同一个尺度范围内，从而提高模型的训练效果和分类精度。

将数据线性缩放到[0,1]的范围,公式如下：

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (45)$$

(2) 特征提取与建模

输入的特征包括励磁波形、材料类型、频率、温度等基本特征，以及磁通密度的统计特征（如均值、标准差、最大值、最小值、峰峰值等），还有能量相关的特征（如总能量、波峰因子、偏度、峰度），以及增强型斯坦麦茨损耗值。这些特征将作为机器学习模型的输入，用于预测磁芯损耗。

$$y_{pred} = f \left(\begin{array}{l} \text{'励磁波形','材料类型','频率','温度'} \\ \text{'Mean', 'Std', 'Max', 'Min', 'Peak-to-Peak','RMS'} \\ \text{'total_energy','crest_factor','Skewness','Kurtosis',} \\ \text{'enhanced_steinmetz_loss'} \end{array} \right) \quad (46)$$

其中， f 为机器学习方法的拟合方程， y_{pred} 是预测出的磁芯损耗。

此外，引入非线性温度修正斯坦麦茨方程可得修正后的磁芯损耗

$$P = k \cdot (f^\alpha) \cdot (B_{\max}^\beta) \cdot \exp(\gamma \cdot T + \delta \cdot T^2 + \eta \cdot X_{\text{interaction}}) \quad (47)$$

其中，拟合非线性温度修正斯坦麦茨方程的最优参数为： k 为 388860， α 为 0.13， β 为 0.27， γ 为 -0.67， δ 为 0.21， η 为 0.42。




图 5-13 多维统计分析图

这组图展示了多个与系统振动、能量和信号特性相关的统计指标在不同工况的变化情况，反映出系统在测试过程中经历了显著的动态行为变化。具体而言，阻尼速率和材料类型分别表现出系统在不同阶段的阻尼状态和材料切换，而频率、均值、标准差等指标则显示了信号的波动性，揭示出系统的振动不稳定性。最大值、最小值和峰峰值表明信号在某些工况达到了极值，可能对应异常工况或高能量事件。RMS 和总能量揭示了系统能量的变化特性，表明不同工况下能量水平波动显著。偏度和峭度反映了信号的统计分布特征，显示出信号在不同工况的非对称性和尖峰性，而增强 Steinmetz 损失则展示了材料的磁性能损耗变化。

(3) 预测模型的选择

用了多个不同的机器学习模型来预测磁芯损耗。这些模型包括:

① 决策树 (Decision Tree)

模型描述:

决策树回归模型通过划分输入特征空间，将每个区域的预测值设为该区域内样本的均值。它依赖于递归的二分法，使用特征及其对应的阈值来分割数据，每次分割使得局部区域的均方误差（MSE）或其他损失函数最小。

公式描述：

$$\hat{y} = f(\mathbf{X}) \quad (48)$$

输入为特征 $\mathbf{X}$ ，输出为预测的磁芯损耗 $\hat{y}$ ，函数 f 是通过划分特征空间学习得到的决策规则。

决策树模型通过一系列的“是/否”二分决策来逐步缩小预测的范围，直到叶子节点，其中存储的值就是最终的预测值。

② 随机森林 (Random Forest)

模型描述：

随机森林是由多个决策树组成的集成学习模型，主要通过“装袋法”（Bagging）来减小模型的方差，从而提高预测精度。在磁芯损耗预测中，随机森林通过构建多棵决策树，利用每棵树对输入数据的不同随机子集进行训练。每棵树的输出是对磁芯损耗的一个估计值，最终通过对所有树的预测结果求平均，来生成最终的磁芯损耗预测值。

公式描述：

$$\hat{y} = \frac{1}{T} \sum_{i=1}^T f_i(\mathbf{x}) \quad (49)$$

其中， $\hat{y}$ 为磁芯损耗的预测值， $f_i(\mathbf{x})$ 是第 i 棵决策树对输入特征 $\mathbf{X}$ 的预测， T 是决策树的总数。

③ XGBoost

模型描述：

XGBoost 是一种基于梯度提升的集成学习方法，通过加权组合多个弱学习器来提高预测精度。其强大的调参能力和优化方法使其在许多回归任务中表现优异。

公式描述：

假设一共有 T 轮迭代，那么最终的预测值可以表示为各轮迭代的结果之和：

$$\hat{y}_i = \sum_{t=1}^T f_t(X_i) \quad (50)$$

其中， f_t 是在第 t 轮迭代时学到的树模型， $f_t \in \mathcal{F}$ ， $\mathcal{F}$ 是所有可能的回归树的空间。

XGBoost 通过最小化损失函数来优化模型，损失函数 L 包括两个部分：模型的训练误差和正则化项，用来控制模型复杂度，防止过拟合。

$$L(\phi) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{t=1}^T \Omega(f_t) \quad (51)$$

其中， $l(y_i, \hat{y}_i)$ 是用于度量真实值 y_i 与预测值 $\hat{y}_i$ 之间误差的损失函数。

$\Omega(f_t)$ 是第 t 棵树的正则化项，用于控制树的复杂度，通常定义为：

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (52)$$

其中， γ 是控制叶节点数的参数， λ 是控制叶节点权重的 L2 正则化系数， w_j 是树的叶节点的权重。

在每一轮迭代中，XGBoost 构建一棵新树来拟合之前轮次模型的残差，即目标是通过新树来最小化每个样本的误差。

给定第 t 轮的预测值为 $\hat{y}_i^{(t)}$ ，我们希望最小化以下目标函数：

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(X_i)) + \Omega(f_t) \quad (53)$$

在训练过程中,通过梯度下降的方式找到最优的树 f_t ,即通过对损失函数进行泰勒展开,对每一棵树的节点权重进行优化:

$$f_t(X) = -\frac{g_i}{h_i + \lambda} \quad (54)$$

$g_i = \partial_{\hat{y}_i^{(t-1)}} l(y_i, \hat{y}_i^{(t-1)})$ 是第 i 个样本的损失函数的一阶梯度; $h_i = \partial_{\hat{y}_i^{(t-1)}}^2 l(y_i, \hat{y}_i^{(t-1)})$ 是第 i 个样本的损失函数的二阶梯度。

通过使用一阶和二阶梯度, XGBoost 能够更精确地进行优化,提高模型的收敛速度和精度。

④ K-近邻 (KNN)

模型描述:

给定一个样本点,找到该样本在特征空间中距离最近的 K 个训练样本点,通过这些样本的类别(分类任务)或数值(回归任务)来预测该样本的结果。

公式描述:

通常, KNN 使用 **欧几里得距离** 来衡量样本之间的相似性。欧几里得距离的公式为:

$$d(X, X_i) = \sqrt{\sum_{j=1}^m (X_j - X_{ij})^2} \quad (55)$$

其中 X_j 和 X_{ij} 分别是待预测样本和训练样本第 j 个特征的值, m 是特征的维数。

K 是算法的一个超参数,它决定了用于预测的邻居数量。常见的选择方法包括交叉验证来选择最优的 K 值。

⑤ 多层感知机 (MLP)

模型描述:

MLP 是一种前馈神经网络,包含多个隐藏层,每一层通过激活函数(如 ReLU 或 sigmoid)对输入进行非线性变换。MLP 的优势在于它能够捕捉复杂的非线性关系,这对于磁芯损耗的预测特别有用,因为损耗与特征(如温度、频率、磁通密度)之间的关系通常是高度非线性的。

公式描述:

对于一个具有输入特征向量 $\mathbf{X} = [x_1, x_2, \dots, x_n]$ 的样本, MLP 的隐藏层通过以下公式计算:

$$\mathbf{Z}^{(1)} = \mathbf{W}^{(1)} \cdot \mathbf{X} + \mathbf{b}^{(1)} \quad (56)$$

其中, $\mathbf{W}^{(1)}$ 是输入层到隐藏层的权重矩阵, $\mathbf{b}^{(1)}$ 是隐藏层的偏置向量, $\mathbf{Z}^{(1)}$ 是未经过激活函数的隐藏层输出。

隐藏层输出 $\mathbf{Z}^{(1)}$ 通过激活函数 g 进行非线性变换:

$$\mathbf{A}^{(1)} = g(\mathbf{Z}^{(1)}) \quad (57)$$

鉴于数据都为正值,本文激活函数采用 ReLU 函数: $g(Z) = \max(0, Z)$ 。

隐藏层的输出 $\mathbf{A}^{(1)}$ 作为输入,传递到输出层:

$$\mathbf{Z}^{(2)} = \mathbf{W}^{(2)} \cdot \mathbf{A}^{(1)} + \mathbf{b}^{(2)} \quad (58)$$

$\mathbf{W}^{(2)}$ 是隐藏层到输出层的权重矩阵, $\mathbf{b}^{(2)}$ 是输出层的偏置向量, $\mathbf{Z}^{(2)}$ 是未经过激活函数的输出。

输出层的激活函数通常是线性函数：

$$\hat{y} = Z^{(2)} \quad (59)$$

MLP 的目标是最小化损失函数均方误差（MSE）：

$$L(\hat{y}, y) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (60)$$

反向传播算法通过链式法则计算损失函数对每个权重的梯度，进而通过梯度下降更新权重：

$$W^{(t+1)} = W^{(t)} - \eta \frac{\partial L}{\partial W^{(t)}} \quad (61)$$

其中， η 是学习率， $\frac{\partial L}{\partial W^{(t)}}$ 是损失函数相对于权重的梯度。




图 5-14 方案三的网络架构图

5.4.4 问题四模型实验与分析

算法都经过 5 折交叉验证，调参，分三种方案进行实验。

（1）方案一：仅使用'励磁波形','材料类型','频率','温度',作为预测特征。

表15 方案一模型误差表

Model	决策树	随机森林	Xgboost	KNN	MLP
RMSE	351323.7	355765.7	350873.9	383984.7	325654.1
MAE	217050.8	219020.4	217633.3	232296.9	216448.6




图 5-15 方案一模型性能对比图

从柱状图和折线图中可以看出，MLP 模型在 RMSE 和 MAE 两个指标上的表现最佳，说明其预测精度高，误差较小。而决策树、KNN 和 xgboost 模型的表现相对较差。




图 5-16 方案一模型真实值与预测值对比图

散点图和回归线图展示了真实值和预测值的对比关系，显示了模型在某些数据点上的预测偏差较大，特别是在极端值情况下，模型的预测误差较为显著。尽管大多数数据点的误差较小，但模型的极端值预测能力仍有待提高。

方案二：基于磁通密度的分布特征和形状特征的实验，旨在揭示电磁设备或材料在磁场中的行为，优化其性能并提高效率。

表16 方案二模型误差表

Model	决策树	随机森林	Xgboost	KNN	MLP
RMSE	139437	100042.2	74512.5	155958.7	58254.6
MAE	60663.5	47792.6	36724.0	56012.9	29124.3




图 5-17 方案二模型性能对比图




图 5-18 方案二模型真实值与预测值对比图

在方案二的实验结果中，XGBoost 和 MLP 模型表现最佳，具有最低的 RMSE 和 MAE 误差，预测精度显著优于其他模型，而 KNN 和随机森林的表现相对较差，误差较高。真实值与预测值的对比图显示，尽管大部分数据点预测准确，但在高值样本上仍存在较大误差，且部分样本的预测值超出 20% 的误差范围。与实验一相比，模型的性能和趋势保持一致，XGBoost 和 MLP 模型在两次实验中展现出优异的稳定性，而 KNN 和随机森林在此类任务中表现较弱，需要进一步优化。

方案三：为了更加精确地预测磁性材料在复杂条件下的能量损耗，优化电磁设备的设计和性能，并解决温度和高频等非线性因素对损耗计算带来的挑战，基于磁通密度的分布特征和形状特征及非线性温度修正 Steinmetz 的方程进行实验。

表17 方案三模型误差表

Metric	决策树	随机森林	xgboost	KNN	MLP
RMSE	99758.3	89308.2	71068.8	155476.6	48776.1
MAE	53762.0	41418.4	35045.5	56847.7	27792.6




图 5-19 方案三模型性能对比图




图 5-20 方案三模型真实值与预测值对比图

方案三结合了磁通密度分布特征、形状特征及非线性温度修正 Steinmetz 方程，在预测磁性材料损耗的实验中，XGBoost 和 MLP 表现最为优异，尤其是 XGBoost 的预测误差最小。然而，在某些极端值情况下，模型的预测误差较大，尤其在处理高值时，模型的稳定性和精度仍有待提升。整体而言，方案三的改进提供了更加精确的预测。

5.4.5 问题四预测结果

由于整体来看，MLP 的预测结果最好，所以本文选择 MLP 为最终的预测模型。

表18 预测结果表

序号	磁芯损耗
16	267807.5
76	830028.7

98	63305.2
126	348545.5
168	872737.7
230	2474.6
271	1769340.8
338	33380.7
348	342764.7
379	62888.9


5.5 问题五模型建立与求解

5.5.1 问题五描述与分析

问题五要求建立优化模型，分析在什么条件下，能达到最小的磁芯损耗以及具有最大的传输磁能。在这一问中，可以将问题四构建的磁芯损耗预测模型作为目标函数，并同时考虑传输磁能指标，通过附件一的实验数据构建多目标优化模型，目标为最小化磁芯损耗、最大化传输磁能。使用遗传算法或粒子群优化算法等进行求解。分析在温度、频率、波形、磁通密度峰值及磁芯材料的影响下，寻找能使磁芯损耗最小化且传输磁能最大化的条件。

在磁性元件的优化中，为了同时实现最小的磁芯损耗和最大的传输磁能，需要构建一个综合的多目标优化模型。传输磁能可通过频率与磁通密度峰值的乘积衡量，而磁芯损耗则受温度、频率、波形和磁芯材料的影响。优化模型的目标是最小化磁芯损耗的同时最大化传输磁能[9]。然而，由于高频率和高磁通密度峰值往往会增加传输磁能，但也可能导致损耗增加，因此在这两者之间存在权衡关系。通过综合分析不同材料、温度和波形的组合，模型能够找到在特定工作条件下的最优解，实现损耗最小化和传输能量最大化的平衡。

5.5.2 问题五技术路线图



5.5.3 问题五模型建立

(1) 目标函数：

目标一：最小化磁芯损耗

$$\min P(T, f, W, B_{peak}, M) \quad (62)$$

目标二：最大化磁芯传输效率

$$\max E(T, f, W, B_{peak}) = f \cdot B_{peak} \quad (63)$$

(2) 约束条件：

问题五要求我们考虑磁芯损耗和传输磁能两个目标。首先，假设在问题四中构建的磁芯损耗预测模型 $L(f, B, T, M, W)$ ，其中是 f 频率， B 是磁通密度的峰值， T 是温度， M 是磁芯材料， W 是励磁波形，传输磁能被定义为 $P = f \times B$ 。

(3) 决策变量：

f 频率，单位为赫兹 (Hz)

B_{peak} 磁通密度峰值，单位为特斯拉 (T)

T 温度，单位为摄氏度 (°C)

M 磁芯材料，选择范围为 $\{1, 2, 3, 4\}$

W 励磁波形，选择范围为 $\{\text{正弦波 (1), 三角波 (2), 梯形波 (3)}\}$

(4) 约束条件：

① 温度约束：

$$T_{\min} \leq T \leq T_{\max} \quad (64)$$

② 频率约束

$$f_{\min} \leq f \leq f_{\max} \quad (65)$$

③ 材料选择约束

$$M \in \{1, 2, 3, 4\} \quad (66)$$

④ 波形约束

波形类型为正弦波、三角波、梯形波；

设波形选择为变量 W ，且 W 值为 1 (正弦波)、2 (三角波)、3 (梯形波)： $W \in \{1, 2, 3\}$

综上，针对问题五建立的数学模型如下：

$$\min P(T, f, W, B_{peak}, M) \quad (67)$$

$$\max E(T, f, W, B_{peak}) = f \cdot B_{peak} \quad (68)$$

$$s.t. \begin{cases} T_{\min} \leq T \leq T_{\max} \\ f_{\min} \leq f \leq f_{\max} \\ M \in \{1, 2, 3, 4\} \\ W \in \{1, 2, 3\} \end{cases} \quad (69)$$

5.5.4 问题五模型求解与分析

(1) 基于粒子群优化算法

粒子群优化算法是一种群体智能优化算法，被广泛应用于各种优化问题，如函数优化、神经网络训练和其他复杂系统的优化。在本题中步骤如下：

Step1: 设置磁芯损耗优化问题参数的搜索范围，包括温度、频率、磁通密度峰值、励磁波形和材料类型。

Step2: 加载第四问中训练好的磁芯损耗预测模型。该模型将根据不同参数组合预测磁芯损耗。

Step3: 设定优化目标：最小化磁芯损耗与传输磁能的比值。

Step4: 每个粒子通过目标函数（即优化目标函数）来评估适应度 (Fitness)，适应度值越小的粒子代表当前更优的解，进入 step5。

Step5: 每个粒子根据当前的局部最优位置（个人历史最优）和全局最优位置（群体最优）更新速度和位置。粒子的更新基于启发式算法来调整其位置，以找到更优解。

Step6: 未达磁芯损耗最小与传输磁能最大，则继续 step4 迭代，直到达到预设的最大迭代次数。或者，若适应度值在多次迭代中变化不大，达到设定的收敛阈值，则停止优化。

Step7: 得到全局最优解(温度、频率、磁通密度峰值、励磁波形和材料类型)，算法结束。




图 5-21 粒子群优化算法流程图

(2) 基于物理引导的粒子群优化算法

在基于物理限制的粒子群优化算法中，每个粒子在更新时，首先检查是否满足磁滞损耗、涡流损耗和剩余损耗的物理约束[10]。磁滞损耗通过限制磁通密度与频率的乘积，涡流损耗通过限制频率的平方，剩余损耗则通过对材料类型进行筛选。若某个粒子不满足这些物理限制，则将其视为无效解，并赋予较大的惩罚值，确保其在后续迭代中不会被选为最优解。这样可以确保优化过程既能追求目标函数的优化，又能符合物理实际约束。

① 磁滞损耗

$$P_h = k_h \cdot f \cdot B_m^\beta \quad (70)$$

其中： f 是频率； B_m 是磁通密度的峰值（最大值）； k_h 和 β 是通过实验数据拟合出的系数。

② 涡流损耗

$$P_{cl} = k_{cl} \cdot f^2 \cdot B_m^2 \quad (71)$$

其中： f 是频率； B_m 是磁通密度的峰值； k_{cl} 则与被测磁芯的截面积与电阻率有关。

③ 剩余损耗

$$P_e = 8 \cdot \sqrt{\sigma \cdot S \cdot G \cdot V_0} \cdot f^{1.5} \cdot B_m^{1.5} \quad (72)$$

其中： σ 是电导率； S 是磁性元件的有效截面积； G 是一个常数 0.1356； V_0 是需拟合的系数。

5.5.5 问题五结果分析

(1) 基于粒子群优化算法




图 5-22 基于粒子群优化算法磁芯损耗与传输磁能随迭代次数变化的对比图

由图可知，磁芯损耗在早期波动较大，随着迭代次数增加逐渐减小并趋于稳定，表明优化过程有效减少了损耗；右图则展示传输磁能在早期迅速增加并趋于稳定，但后期仍有一定波动，反映出优化过程中传输磁能的提升伴随较大的波动，可能存在局部最优现象。整体而言，优化过程在减少损耗和提高传输磁能上表现出不同的收敛特性。

表19 基于粒子群优化算法磁性材料参数表

参数	值
材料	材料 3
温度, °C	25
频率, Hz	500000.00
励磁波形	正弦波
最大值 (峰值)	0.9934

基于粒子群优化算法的磁芯损耗和传输磁能大小如下表所示：

表20 基于粒子群优化算法磁芯损耗和传输磁能值表	
目标	值
磁芯损耗	7272.91
传输磁能大小	496689.48

（2）基于物理引导的粒子群优化算法




图 5-23 基于物理引导的粒子群优化算法磁芯损耗与传输磁能随迭代次数变化的对比图

上图说明了优化算法在损耗最小化和传输磁能最大化方面的效果。随着迭代次数的增加，磁芯损耗逐渐减少，并在后期收敛至较低值；传输磁能在早期快速提升后，经历了较长时间的波动，最终趋于稳定。这表明优化过程在有效减少损耗的同时，提高了传输磁能，且两者的收敛速度不同。

表21 基于物理引导的粒子群优化算法的磁性材料参数表	
参数	值
材料	材料 3
温度，℃	25
频率，Hz	99999.98
励磁波形	正弦波
最大值（峰值）	0.9930

基于粒子群优化算法的磁芯损耗和传输磁能大小如下表所示：

表22 基于物理引导的粒子群优化算法的磁芯损耗和传输磁能值表	
目标	值
磁芯损耗	7272.91
传输磁能大小	99297.62

六、模型的评价与推广

6.1 模型的优点

1. 针对问题一所建立的基于随机森林算法的模型对不同材料的励磁波形进行分类，预测值与真实值拟合基本匹配，模型的准确率较高，证明了该模型的可行性与通用性。

2. 针对问题二的斯坦麦茨方程修正，我们提出了适用于更复杂环境下的斯坦麦茨方程，能更好地捕捉到了实际损耗的波动趋势，模型拥有高拟合优度，验证了该模型的适用性与可行性。

3. 针对问题三的各元素影响磁芯损耗问题，我们做出了多个假设，充分考虑了线性与非线性的解决方案，通过数据可视化直观地展现了元素间的协同作用，通过显著性水平和误差验证了该模型的适用性。

4. 针对问题四构建高精度且适用性高的损耗模型，我们采用了决策树、随机森林、XGBoost、KNN、多层感知机五种算法，并采取了三种方案进行对比拟合，获得了最佳损耗模型。

5. 针对问题五构建兼顾最小损耗和最大传输磁能的损耗模型，我们在优化过程中引入物理约束，建立了基于物理引导的粒子群优化的优化模型，经过多个方案对比，我们的模型效果优越。

6.2 模型的缺点

1. 由于本文采用数据驱动的方法进行建模和优化，因此模型的表现高度依赖于数据的质量和数量。如果实验数据不准确或存在噪声，模型的预测性能可能会受到较大影响。

2. 尽管模型在数据处理上进行了优化，但样本数量的限制依然是影响训练效果的重要因素，需在未来研究中考考虑增加样本量以提高模型的鲁棒性。

参考文献

- [1] 沈春城,严柏平,黄大卓,等.基于波形复杂特性的励磁涌流快速识别算法研究[J].电气工程学报,2024,19(01):243-253.
- [2] 王泽瑞.基于振动信号的变压器铁心状态检测与诊断方法[D].华北电力大学(北京),2022.DOI:10.27140/d.cnki.ghbbu.2022.000595.
- [3] G. Bertotti, "General properties of power losses in soft ferromagnetic materials," in IEEE Transactions on Magnetics, vol. 24, no. 1, pp. 621-630, Jan. 1988, doi: 10.1109/20.43994.
- [4] 张国栋.高磁导率低损耗铁基软磁复合材料的制备与降损机理[D].山东大学,2021.DOI:10.27272/d.cnki.gshdu.2021.002110.
- [5] 戴金辉.单因素方差分析中异方差的检验与修正.统计与决策, 2017, 8: 23-26.
- [6] 钱莹; 方秀男.多元线性回归模型及实例应用.中国科技信息, 2022, 4: 73-74.
- [7] 谢文轩.含零电压激励波形的磁芯损耗模型研究[D].南京邮电大学,2022.DOI:10.27251/d.cnki.gnjdc.2022.001315.
- [8] 汪晶慧, 陈为.超低损耗角磁芯损耗测量的量热计法[J].电工电能新技术, 2012, 31(4): 6-9.
- [9] 万敏平, 杨艳.磁流体湍流中的结构和能量传输[J].空气动力学学报, 2020, 38(1): 160-170.
- [10] 郑加驹, 王洪礼, 曹淑瑛.超磁致伸缩驱动器频率相关的动态磁滞模型[J].机械工程学报, 2008, 44(7): 38-44.

附录

附录 1

第一问求解主要代码

算法 1：提取统计特征的算法

输入：row 表示每行数据

输出：提取后的统计特征列表

1. 定义 `extract_stat_features(row)`
2. 计算均值 `mean_val = row` 的均值
3. 计算标准差 `std_val = row` 的标准差
4. 计算最大值 `max_val = row` 的最大值
5. 计算最小值 `min_val = row` 的最小值
6. 计算峰峰值 `peak_to_peak = max_val - min_val`
7. 计算均方根 `rms_val = sqrt(mean(row^2))`
8. 返回 `[mean_val, std_val, max_val, min_val, peak_to_peak, rms_val]`

算法 2：提取波形特征的算法

输入：row 表示每行数据

输出：提取后的波形特征列表

1. 定义 `extract_waveform_features(row)`
2. 将 `row` 转换为浮点型
3. 计算总能量：
4. `fft_result =` 对 `row` 进行 FFT 变换
5. `fft_magnitude =` 取 `fft_result` 的绝对值
6. `total_energy = fft_magnitude^2` 的总和
7. 计算峰值因子：
8. `peak_value = row` 的绝对值最大值
9. `rms_value = sqrt(mean(row^2))`
10. `crest_factor = peak_value / rms_value`
11. 计算波形不对称度 `skewness_value = row` 的偏度
12. 计算波形的尖度 `kurtosis_value = row` 的尖度
13. 返回 `[total_energy, crest_factor, skewness_value, kurtosis_value]`

第二问求解主要代码

算法 1：拟合斯坦麦茨方程与修正方程

输入：预处理后的数据集

输出：拟合的参数与误差对比

1. 定义斯坦麦茨方程模型 `steinmetz_model`
输入：频率，参数 `alpha` 和 `k`
输出：磁芯损耗的预测值
2. 对数据进行对数线性化处理
3. 使用最小二乘法拟合斯坦麦茨方程
 - 设定初始猜测参数
 - 进行最小化优化，提取 `alpha` 和 `k` 参数
4. 构造修正方程 `enhanced_corrected_steinmetz`，加入温度和交互项的影响
输入：频率、磁通密度峰值、温度和交互项
输出：改进后的磁芯损耗预测值
5. 使用最小二乘法拟合修正方程
 - 设置初始参数并进行最小化拟合
 - 提取优化后的参数

算法 2：遗传算法优化斯坦麦茨方程

输入：预处理后的数据集，优化参数范围

输出：拟合的参数与误差对比

1. 定义改进的修正斯坦麦茨方程 `enhanced_corrected_steinmetz`:
 - 输入参数包括频率、磁通密度峰值、温度和交互项
 - 输出磁芯损耗预测值
2. 定义遗传算法的适应度函数 `fitness`:
 - 对预测结果与实际损耗进行均方误差计算
3. 设置遗传算法的参数上下限
4. 使用遗传算法进行优化:
 - 设定遗传算法策略和参数（如迭代次数、种群大小、变异率、重组率等）
 - 最小化适应度函数，找到最佳拟合参数
5. 提取优化后的参数

第三问求解主要代码

算法 1：数据读取与预处理

输入：Excel 数据文件

输出：处理后的数据集

1. 读取 Excel 数据文件
2. 选择所需的列：磁芯材料、温度、磁芯损耗、励磁波形
3. 将分类变量编码为数值
 - 编码磁芯材料为数值
 - 编码励磁波形为数值
4. 准备特征与目标变量：
 - 特征 X：温度、磁芯材料编码、励磁波形编码
 - 目标变量 y：磁芯损耗
5. 构建交互项：
 - 温度*材料
 - 温度*波形
 - 材料*波形
6. 添加常数项用于 OLS 回归分析

算法 2：回归分析与显著性评估

输入：特征 X 和目标变量 y

输出：回归结果与显著性评估

1. 构建 OLS 回归模型
2. 进行回归分析，输出回归结果
3. 使用 F 检验评估交互项的显著性
 - 输出 ANOVA F 检验结果

算法 4：部分依赖图与最优组合筛选

输入：测试集和预测结果

输出：磁芯损耗最小的组合

1. 绘制部分依赖图，分析温度、材料和波形的交互影响
2. 获取随机森林模型在测试集上的预测结果
3. 找到预测磁芯损耗最小的组合
4. 提取对应的最优条件组合
 - 将编码的材料和波形映射为实际名称
5. 输出磁芯损耗最小的组合

第四问求解主要代码

算法 1：第一次优化 - 使用工况条件、励磁波形和磁芯材料的优化

输入：训练集（包含工况条件、励磁波形、磁芯材料）

输出：第一次优化后的预测结果

1. 读取训练集数据
2. 提取工况条件、励磁波形和磁芯材料作为输入特征
3. 使用第一问中提取的分布特征和形状特征进行扩展：
 - 分布特征：均值、标准差、峰值等
 - 形状特征：波形不对称度、尖度等
4. 构建模型进行初次优化
 - 输入：工况条件、励磁波形、磁芯材料以及提取的特征
 - 输出：初步的磁芯损耗预测结果
5. 保存优化后的模型和结果

算法 2：第二次优化 - 使用修正的斯坦麦茨拟合公式进行优化

输入：第一次优化后的结果与修正斯坦麦茨拟合公式

输出：最终优化后的预测结果

1. 通过第二问中斯坦麦茨拟合公式，对温度进行修正：
 - 获取温度修正后的斯坦麦茨方程
 - 对训练集进行拟合，得到修正后的磁芯损耗
2. 将修正后的磁芯损耗作为新的特征添加到输入特征集中
3. 使用包含修正后的磁芯损耗的新特征，重新构建模型进行二次优化
 - 输入：工况条件、励磁波形、磁芯材料、修正后的磁芯损耗
 - 输出：二次优化后的最终磁芯损耗预测结果
4. 保存最终优化后的模型和结果

第五问求解主要代码

算法 1：物理约束函数定义

输入：优化参数 x

输出：物理约束是否满足

1. 定义 `physical_constraints(x)`
2. 计算磁滞损耗约束：
 - $\text{hysteresis_loss} = B_{\text{peak}} * \text{frequency}$
 - 若 $\text{hysteresis_loss} > \text{磁滞损耗上限}$ ，返回 `False`
3. 计算涡流损耗约束：
 - $\text{eddy_current_loss} = \text{frequency}^2$
 - 若 $\text{eddy_current_loss} > \text{涡流损耗上限}$ ，返回 `False`
4. 限制材料的选择：
 - 若 `material` 不属于允许的材料列表，返回 `False`
5. 若所有约束均满足，返回 `True`

算法 2：目标函数定义

输入：优化参数 x

输出：目标函数值

1. 定义目标函数 `objective(x)`
2. 判断是否满足物理约束：
 - 若 `physical_constraints(x)` 返回 `False`，返回无穷大作为惩罚值
3. 若满足约束，计算目标函数值：
 - 目标函数值 = $w1 * \text{模型预测值} + w2 * (-\text{频率} * \text{磁通密度峰值})$
4. 返回目标函数值

算法 3：优化过程

输入：初始参数 x 和目标函数

输出：优化后的结果

1. 设定优化初始参数 x
2. 调用优化算法（如粒子群、遗传算法等），最小化目标函数
3. 在每次迭代中调用 `objective(x)`，检查物理约束并计算目标函数值
4. 返回优化后的最优参数组合和对应的目标函数值