



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 河南师范大学

参赛队号 23104760078

1.欧阳瑶

队员姓名 2.毛艺臻

3.王志龙

中国研究生创新实践系列大赛
“华为杯”第二届中国研究生
数学建模竞赛

题 目： 出血性脑卒中临床智能诊疗建模

摘 要：

出血性脑卒中起病急、进展快，预后较差，急性期内病死率高达 45-50%，为社会及患者家庭带来沉重的健康和经济负担。因此，发掘出血性脑卒中的发病风险，精准预测患者预后具有重要的意义。

针对问题一：主要目标是血肿扩张风险相关因素探索建模。子问题 a 要求判断患者发病后 48 小时内是否发生血肿扩张，并记录血肿扩张发生时间。首先通过整合表 1，表 2 和附表 1 中相关字段的数据，保留 HM_volume、入院首次检查及随访时间等关键字段；接着排除发病到第一次随访时间的时间间隔大于 48 小时的数据，再根据这两次检查的 HM_volume 的绝对体积差或相对体积差保留发生血肿患者的相关数据并记录血肿扩张发生时间。对于暂时没有发生血肿的患者，继续重复以上步骤，以上步骤进行到第八次随访即可将所有数据筛选完。最终得到 sub003、sub005 等 24 名患者在 48 小时内发生脑血肿扩张。子问题 b 要求预测所有患者发生血肿扩张的概率。首先对数据进行预处理：将部分数据进行量化、将全部数据进行标准化；接着基于患者的糖尿病史、高血压病史等 72 个影响因素，分别使用了多因素 Logistic 回归、MLP 神经网络、决策树、随机森林来预测该患者发生血肿扩张的概率，其中**多因素 Logistic 回归模型**的预测准确度最高。在使用多因素 Logistic 回归模型进行预测之前，通过网格搜索法、交叉验证法来进行参数调整，使预测效果达到了较理想的水平。最后对结果进行分析，发现有 26 名患者发生血肿扩张的可能性较大。

针对问题二：主要目标是血肿周围水肿的发生及进展建模，并探索治疗干预和水肿进展的关联关系。子问题 a 主要目标是构建全体患者水肿体积随时间进展的曲线并计算残差。进行数据预处理后得到 336 组数据（时间间隔和其相对应的水肿体积），在探索合适的拟合方法过程中，也在逐步改进：将时间间隔的最小单位每天精确到每小时、剔除异常值、用不同颜色将不同患者的情况进行区分等，最后使用**四次多项式回归**进行拟合达到了理想的拟合效果。结果显示：发病后 300 小时内，是患者水肿扩张高发期，因此在这期间，对脑卒中患者进行观测干预治疗尤为重要。子问题 b 主要目标是根据患者的个体差异将人群分

类，构建出不同类人群水肿体积随时间进展的曲线。首先根据患者疾病史、生活习惯等个性差异，使用 **K-means 聚类分析** 将人群分为了 4 类；其次基于子问题 a 得出的使用相应的改进方法后，用四次多项式回归来拟合相关曲线效果理想的结论，继续同样的改进方法和拟合方法即可。**子问题 c** 主要目标是分析脑室引流、止血治疗等 7 种治疗方法对水肿体积进展模式的影响。使用机器学习中的梯度提升机模型来分析，定义脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经作为特征，水肿进展模式作为目标。将数据集划分为训练集和测试集。在训练模型部分，使用**梯度提升机模型**，用训练集对其进行训练。然后使用测试集对模型进行预测，并输出关于模型好坏的分类报告，通过优化模型来提高准确度并且计算出特征的重要性、绘制图形，展示这 7 种治疗方案对水肿体积进展模式的影响程度。**子问题 d** 主要目标是分析血肿体积、水肿体积及 7 种治疗方法之间的关系。首先使用的**皮尔逊相关系数**进行分析的效果并不理想，分析发现血肿体积、水肿体积等变量分布呈严重非正态、7 种治疗方法不是连续变量，直接影响了皮尔逊相关系数的结果准确度，而**斯皮尔曼相关系数**可以完美解决这类问题。使用斯皮尔曼相关系数两两分析这 9 种变量之间的关系，结果显示：降颅压治疗对治疗和缓解血肿、水肿扩张的效果最好，同时使用多种治疗手段进行治疗的效果优于单个治疗手段的效果。

针对问题三：主要目标是对出血性脑卒中患者预后预测及关键因素探索。**子问题 a** 主要目标是根据前 100 个患者的疾病史、首次影像结果等相关情况构建模型来预测患者 90 天 mRS 评分。也即预测患者预后的身体状况，并分为 7 种类型。本文分别采用了随机森林和支持向量机分类（SVC）进行预测，使用混淆矩阵、准确率、召回率等指标对它们进行评估，最终的结果指向了**支持向量机分类（SVC）**。**子问题 b** 的主要目标是根据前 100 个患者的疾病史、首次和随访的影像结果等相关情况构建模型来预测含随访影像检查患者的 90 天 mRS 评分。相较于子问题 a，不一样的是该问题增加了几个因素：患者随访的影响结果，所以整个问题的预测会更加准确。与子问题 a 类似的，同样采用随机森林和支持向量机分类（SVC）进行预测，使用混淆矩阵、准确率、召回率等指标对它们进行评估，但这次不同的是最终结果指向了**随机森林**。**子问题 c** 的主要目标是分析出血性脑卒中患者的 90 天 mRS 和个人史、疾病史、治疗方法、血肿，水肿体积、血肿，水肿位置、信号强度特征、形状特征等关联关系，并提出建议。综合分析子问题 b 的相关结果并采用了文字挖掘技术，深入研究预后与患者疾病史、治疗方法等相关特征的主要影响，并根据它们之间的关系，提出相关临床决策的建议，希望给与患者更好的治疗方案。

关键词：多因素 Logistic 回归模型、梯度提升机模型、斯皮尔曼相关系数、K-means 聚类分析、支持向量机分类（SVC）、随机森林

目 录

1 问题重述	5
1.1 问题背景	5
1.2 待解决问题	5
2 基本假设与符号说明	6
2.1 基本假设	6
2.2 符号说明	6
3 问题一模型的建立与求解	6
3.1 子问题 a	6
3.1.1 问题分析	6
3.1.2 模型的建立与求解	6
3.2 子问题 b	9
3.2.1 问题分析	9
3.2.2 数据预处理	9
3.2.3 模型的建立与求解	9
4 问题二模型的建立与求解	11
4.1 子问题 a	11
4.1.1 问题分析	11
4.1.2 模型的建立与求解	11
4.2 子问题 b	14
4.2.1 问题分析	14
4.2.2 模型的建立与求解	14
4.3 子问题 c	17
4.3.1 问题分析	17
4.3.2 模型的建立与求解	17
4.4 子问题 d	19
4.4.1 问题分析	19
4.4.2 模型的建立与求解	19
5 问题三模型的建立与求解	21
5.1 子问题 a	21
5.1.1 问题分析	21
5.1.3 模型的建立与求解	21
5.2 子问题 b	22
5.2.1 问题分析	22
5.2.2 模型的建立与求解	22
5.3 子问题 c	23
5.3.1 问题分析	23
5.3.2 模型的建立与求解	23
6 模型评价与推广	25
6.1 模型优点	25
6.2 模型缺点	25

6.3 展望	25
参考文献	26
附录	27

1 问题重述

1.1 问题背景

出血性脑卒中多发生于中老年人群，随着我国老龄化现象的加剧，出血性脑卒中的发病率也在逐渐上升。此外，由于生活方式和饮食结构的改变，高血压、高血脂、糖尿病等疾病的发生率也在逐年增加，这些疾病都可能增加出血性脑卒中的风险。

出血性脑卒中是一种由于脑部血管突然破裂或因血管堵塞导致血液不能流入大脑而引起脑组织损伤的一组疾病，出血性脑卒中占全部脑卒中发病率的 10-15%。出血性脑卒中的诱因很多，高血压、颅内动脉瘤、脑血管畸形破裂、颅内肿瘤出血、颅内动脉炎等颅内疾病以及血液病、败血症等其他系统疾病都可能导致脑出血。在出血性脑卒中发生时，可能会出现头痛、恶心、呕吐等症状，严重时还可能导致颅内压增高、脑疝形成，甚至危及生命。出血性脑卒中起病急、进展快，预后较差，急性期内病死率高达 45-50%，约 80% 的患者会遗留较严重的神经功能障碍，为社会及患者家庭带来沉重的健康和经济损失。

因此，研究出血性脑卒中的发病风险，结合影像学特征、患者临床信息和诊疗方案，精准预测患者预后，据此优化临床决策具有重大的临床意义。

血肿扩张和血肿周围水肿的发生及发展是预后不良的重要危险因素，针对这两个因素进行早期识别和预测，对于改善患者预后、提升其生活质量具有重要意义；医学影像技术为无创动态监测出血性脑卒中后脑组织损伤和演变提供了有力手段，针对海量患者的影像信息和医疗数据，构建智能诊疗模型，明确导致出血性脑卒中预后不良的危险因素，实现精准个性化的疗效评估和预后预测，有突出的意义。

1.2 待解决问题

问题一：关于血肿扩张风险相关因素的探索建模。

a: 根据表 1 和 2 相关字段的数据，判断患者 sub001 至 sub100 发病后 48 小时内是否发生血肿扩张事件，如果发生血肿扩张事件，记录下血肿扩张发生时间。

b: 以是否发生血肿扩张事件为目标变量，基于表 1 前 100 例患者的个人史，疾病史，发病及治疗相关特征、表 2 中其影像检查结果及表 3 其影像检查结果等变量，构建模型预测所有患者发生血肿扩张的概率。

问题二：关于血肿周围水肿的发生及进展建模，并探索治疗干预和水肿进展的关联关系。

a: 根据表 2 前 100 个患者的水肿体积和重复检查时间点，构建一条全体患者水肿体积随时间进展曲线，x 轴为发病至影像检查时间，y 轴为水肿体积，计算前 100 个患者真实值和所拟合曲线之间存在的残差。

b: 探索患者水肿体积随时间进展模式的个体差异，构建不同人群（分亚组：3-5 个）的水肿体积随时间进展曲线，并计算前 100 个患者真实值和曲线间的残差。

c: 分析不同治疗方法对水肿体积进展模式的影响。

d: 分析血肿体积、水肿体积及治疗方法三者之间的关系。

问题三：关于出血性脑卒中患者预后预测及关键因素探索

a: 根据前 100 个患者的个人史、疾病史、发病相关及首次影像结果构建预测模型，预测患者（sub001 至 sub160）90 天 mRS 评分。

b: 根据前 100 个患者所有已知临床、治疗、表 2 及表 3 的影像结果，预测所有含随访影像检查的患者（sub001 至 sub100, sub131 至 sub160）90 天 mRS 评分。

c: 分析出血性脑卒中患者的预后（90 天 mRS）和个人史、疾病史、治疗方法及影像特征（包括血肿/水肿体积、血肿/水肿位置、信号强度特征、形状特征）等关联关系，为临

床相关决策提出建议。

2 基本假设与符号说明

2.1 基本假设

(1) 对于时间间隔大于 48 小时并且发生血肿的患者，假设其 48 小时内没有发生血肿。

(2) 患者 48 小时后发生血肿扩张的概率不予考虑。

2.2 符号说明

符号	含义
J	绝对体积增加量
X	相对体积增加量
i	随访的次数
HM_volume_i	第 i 次随访检查的 HM_volume 结果
P	发生血肿扩张的概率
r_s	斯皮尔曼相关系数
d_i	变量等级之间的差值

3 问题一模型的建立与求解

3.1 子问题 a

3.1.1 问题分析

要确定患者发病后 48 小时内是否发生血肿扩张以及血肿扩张发生时间，所需的数据分别分布在表1、表2和附表1中。所以首先要将三个表的数据进行整合，保留 HM_volume 、入院首次检查时间及随访次数时间等所需字段数据；接着排除发病到首次影像检查时间间隔与第一次随访时间、首次检查时间的差值之和大于 48 小时的数据，再根据这两次检查 HM_volume 的结果的绝对体积差或相对体积差保留发生血肿患者的相关数据并记录血肿扩张发生时间，排除的患者即为 48 小时内未发生血肿扩张事件。对于暂时没有发生血肿的患者，继续重复以上步骤，先排除发病到首次影像检查时间间隔与第二次随访时间、首次检查时间的差值之和大于 48 小时的数据，再根据首次检查和第二次随访检查 HM_volume 的结果的绝对体积差或相对体积差保留发生血肿患者的相关数据并记录血肿扩张发生时间.....以上步骤进行到第八次随访即可确定所有患者在 48 小时内是否发生血肿扩张事件。对于部分患者从发病到检查时间的间隔大于 48 小时并发生血肿的患者并不能确定其 48 小时内是否发生水肿，因此子问题 a 是在假设这些患者 48 小时内没有发生水肿基础上进行的。

3.1.2 模型的建立与求解

绝对体积增加量：

$$J = HM_volume_i - HM_volume_0$$

相对体积增加量：

$$X = \frac{HM_volume_i - HM_volume_0}{HM_volume_i}$$

判断患者 48 小时内是否水肿的具体步骤见下图 3.1.1：




图 3.1.1 模型流程图

判断这 100 名患者发病后 48 小时内是否发生血肿扩张以及发生血肿扩张的时间见支

撑材料，下表 3.1.1 为 48 小时内发生血肿扩张的 24 名患者信息及血肿扩张时间：

表 3.1.1 48 小时内发生血肿扩张的 24 名患者信息

首次影像检查流水号		是否发生血肿扩张 1 是, 0 否	血肿扩张时间
sub003	201604130000006	1	9.52 小时
sub005	20161222000978	1	26.47 小时
sub009	20161031001987	1	40.05 小时
sub016	201611300000004	1	7.35 小时
sub017	20160510002436	1	14.87 小时
sub033	20170115000362	1	30.80 小时
sub036	20170204001714	1	39.50 小时
sub038	20170518002194	1	15.80 小时
sub039	20170425002487	1	29.17 小时
sub048	20170402000556	1	12.85 小时
sub054	20170612002216	1	16.22 小时
sub057	20170825001844	1	14.60 小时
sub060	20180109000613	1	22.88 小时
sub061	20180226000725	1	6.53 小时
sub063	20181020001229	1	27.75 小时
sub076	20180619002401	1	15.98 小时
sub077	20180503002304	1	14.12 小时
sub079	20180929000037	1	27.83 小时
sub080	20180130001917	1	20.57 小时
sub081	20180120000249	1	27.42 小时
sub092	20181116001089	1	11.92 小时
sub095	20180316001329	1	7.42 小时
sub098	20180612002507	1	42.75 小时
sub099	20180620002296	1	17.67 小时

由表 3.1.1 可以看出，有 4 人在 10 小时之内发生血肿扩张，有 13 人在 20 小时内发生血肿扩张，有 20 人在 30 小时内发生血肿扩张，其余 4 人在 30 至 48 小时内发生血肿扩张。出血性脑卒中的血肿扩张时间主要发生在 30 小时之内，特别是 20 小时之内。在脑出血发生后的 48 小时之后，血肿扩张的可能性很小。

对于血肿的扩张，无论因何引起，均应引起重视，时刻注意血肿的状况。如发现有可能引起血肿者，应立即求医，保证获得恰当处理；切忌自行治疗，否则会使病情恶化，使医生难以处理；时刻注意病情变化并密切注意血肿改变情况，包括血肿体积、颜色和形状，如有改变应及时告知医师；血肿未全部消散时需避免剧烈活动以避免病情的恶化；遵医嘱并严格按照医生建议及治疗方案进行治疗，其中包括药物治疗及物理治疗，在未得到医生指导的情况下，血肿不可以采用任何药物进行治疗；在日常的生活当中，还应该重视饮食问题，合理饮食对回复健康是有帮助的，必要时医生还会提供一些具体的饮食建议。这些都是血肿扩张时的注意事项。当出现血肿特别是脑部血肿时，一定要及时求医以获得专业医疗治理。发生血肿之后，患者家属和医生都要实时监控病情的发展及变化，有情况迅速

沟通做出正确的决策给出合理的治疗方案，减少病情风险性的增加，为患者的健康保驾护航。

3.2 子问题 b

3.2.1 问题分析

该问题的主要目标是基于患者的高血压病史、糖尿病史、冠心病史等 72 个因素来预测该患者发生血肿扩张的概率。由于大部分患者 48 小时后的病情会趋于稳定，因此本文重点关注 48 小时内患者发生血肿扩张的概率。

首先对数据进行预处理，将表 1、表 2、表 3 相关字段的数据以及 a 题关于是否血肿扩张的患者数据进行整合；对性别这一因素进行量化；将血压这一因素的相关数据进行分割；对所有数据进行标准化，使它们在同一个维度。

其次分别使用了多因素 Logistic 回归^[1]、MLP 神经网络^[2]、决策树^[3]、随机森林^[4]来预测该患者发生血肿扩张的概率，通过综合对比，发现多因素 Logistic 回归模型的预测效果最佳。

在使用多因素 Logistic 回归模型进行预测之前，对 penalty、max_iter、solver、C、tol 这 5 个参数进行调整，使该模型的预测效果达到较好的水平。

3.2.2 数据预处理

1. 将表 1、表 2、表 3 相关字段的数据以及 a 题关于是否血肿扩张的患者数据进行整合，生成一个只有患者名、72 个影响因素、是否发生血肿这些字段相关数据的表格；
2. 将性别进行量化，男生设置为 1，女生设置为 0；
3. 将血压这一类的数据进行分割，分割为高压和低压两种；
4. 将所有数据进行标准化，使其在同一维度，数据标准化的公式如下：

$$N = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

3.2.3 模型的建立与求解

多因素 Logistic 回归、MLP 神经网络、决策树、随机森林都可以用来预测患者发生血肿扩张的概率，为了选出最适合子问题 b 的模型，首先客观的分析这四个模型对于子问题 b 而言的优缺点，接着分别用这四个模型进行预测，综合分析它们结果的准确度（例如 best_score_ 的值）来选出最优模型。最后认为多因素 Logistic 回归模型为适合子问题 b 的最优模型。

对于子问题 b 而言，MLP 神经网络的缺点：MLP 神经网络需要输入具有一定结构的数据并且对输入数据的异常值较为敏感，因此对数据进行预处理的要求较高，会增加数据处理的复杂度以及计算成本；与传统的神经网络相比，MLP 神经网络中的参数和决策过程难以理解和解释，这就导致了模型的可信度和可接受性大大降低；

对于子问题 b 而言，决策树的缺点：容易出现过拟合问题，因为模型容易生成一个较复杂的模型，生成的该模型对数据的泛化性能很差；稳定性能差，数据中的微小变化就可能导致完全不同的树生成，因此模型对数据的变化很敏感；对连续性字段的预测比较困难，需要额外的对相应字段进行处理，效率不高；对于特征关联性比较强的数据处理情况不佳。

对于子问题 b 而言，随机森林的缺点：对一些训练数据会出现过度拟合，从而在新数据上表现效果不好；对于取值划分较多的属性，随机森林在这种数据上产出的属性权值不够准确。

在 Logistic 回归预测模型中因变量 P 为是否发生血肿扩张，0 代表患者不会出现血肿扩张，1 代表患者会出现血肿扩张，自变量为患者的高血压病史、糖尿病史、冠心病史等

72 个因素。多因素 Logistic 回归预测模型的公式：

$$P = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_{72} X_{72}}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_{72} X_{72}}}$$

选择这个公式的主要原因是因为 P 的取值范围在 0 到 1 之间，其中 β_0 为常数项， $\beta_1, \beta_2, \beta_3, \dots, \beta_{72}$ 为偏回归系数， P 的数值越大说明该患者发生血肿扩张的可能性越大，0 代表患者不会出现血肿扩张，1 代表患者会出现血肿扩张，所以 P 的数值也是患者发生血肿扩张的概率。

使用多因素 Logistic 回归预测模型来预测所有患者发生血肿扩张的概率的具体结果见支撑材料，通过对最终的结果进行分析，发现有 26 名患者发生血肿扩张的概率较大，如表 3.2.1 所示。

表 3.2.1 发生血肿扩张概率较大的患者名单

	首次影像检查流水号	血肿扩张预测概率
sub052	20170608001310	0.9855
sub009	20161031001987	0.9537
Sub138	20200403000012	0.9209
Sub081	20180120000249	0.9043
Sub118	20190923002580	0.8963
Sub098	20180612002507	0.8906
sub054	20170612002216	0.8667
sub061	20180226000725	0.8611
sub099	20180620002296	0.8596
Sub143	20200214000572	0.8570
Sub063	20181020001229	0.8562
sub048	20170402000556	0.8490
Sub151	20201023001238	0.8484
sub076	20180619002401	0.8347
sub017	20160510002436	0.8264
sub079	20180929000037	0.8236
sub077	20180503002304	0.8225
sub092	20181116001089	0.8089
sub016	20161130000004	0.8032
sub039	20170425002487	0.7983
sub057	20170825001844	0.7884
Sub003	20160413000006	0.7769
sub008	20161219000091	0.7727
sub080	20180130001917	0.7687
sub060	20180109000613	0.7682
Sub005	20161222000978	0.7621

使用多因素 Logistic 回归预测模型来预测所有患者发生血肿扩张的概率，表 3.2.1 展示

了血肿扩张概率大于 75% 的患者，针对这些患者，要时刻注意其病情变化，以便及时治疗。

早确定血肿扩张高危患者可有效对患者进行救治。鉴于预测血肿扩张的研究资料，潜在预测指标可以划分为 4 种类型：

1、临床特征

在意识水平方面，格拉斯哥昏迷量表(GCS)及国立卫生研究院卒中量表得分(NIHSS)已被定为死亡率及严重残疾因子，有研究还将其作为血肿扩张预测因子，认为意识障碍可作为脑出血症状发作者常规过程与血肿扩张同时恶化；关于血糖：50%以上的卒中患者存在高血糖，且不仅住院期间高血糖，而且低血糖还可增加危重病人死亡率，所以临床中应注意避免低血糖及高血糖；关于血压：脑出血病人住院期间血压高与其不良预后成正相关，且有研究认为高血压更多的是与大体积血肿及血肿的扩大有关，这就使早期血压有可能是一个通过缓解血肿扩张来取得较好效果的对象。

2、实验室检查

有关凝血状态：凝血状态的变化可增加受伤后周围血管出血的危险，而且这一作用可维持 24 小时以上，并可使血肿扩张生长；在炎症与微血管完整性方面：医学研究认为炎症反应与微血管完整性损伤与脑出血后脑损伤病理生理过程有关，且根据血管损伤与炎症反应上述分子特征提示后续血肿扩大，且在病症发作前 1 小时最易测得。

3、影像学标准

对于脑出血从发病到首次 CT 之间的间隔时间，有研究指出活动性出血在 6 小时内似乎是稳定的，血肿扩张的可能性随着间隔时间的延长而降低，这就意味着脑出血患者入院或者首次 CT 扫描之间的间隔时间对血肿扩张有很强的预测作用；有关基线血肿的容积、脑出血的数量与近期及远期死亡率均有明显的正相关；有关血肿在 CT 中的形态及密度：血肿在 CT 扫描中形态不规则，密度不均，似提示血肿扩张。

4、预测评分模型

可采用部分血肿扩张预测评分系统，在四个公认的预测因子上建立了一个 9 分的临床预测分数，利用时间间隔、抗凝药物应用、脑出血体积及 CTA 点征进行临床预测评分。最高得分 9 的患者发生血肿扩张的风险为 80%，而最低分 0 的患者血肿扩张发生率仅为 5.7%。高分组（4 至 9 分）与血肿扩张风险呈明显正相关。

4 问题二模型的建立与求解

4.1 子问题 a

4.1.1 问题分析

首先需要对数据进行预处理，得到拟合所需要的数据集：时间间隔和所对应的水肿体积，接着选择合适的拟合方法，这也是问题的关键所在，拟合方法有很多，但是准确度却不尽相同，需要找出最适合这组数据的最佳拟合方法。

在探索合适拟合方法的过程中，总结了上一个拟合方法拟合效果不好的原因，并不断做改进，从而选择出准曲率最高的拟合方法。

表 2 中的数据并没有直接给出检查的时间，所以首先需要提取出检查流水号的前 8 位表示日期的数字，接着分别算出每位患者每次检查与发病的时间间隔（单位为天）和这次检查的血肿体积，这样一共得到了 336 组数据。

当然，这只是初步的数据预处理，当一个拟合方法效果不理想时，还需要总结不足，也会继续进行数据预处理。

4.1.2 模型的建立与求解

在拟合之前先进行初步的数据预处理，由于表 2 提供的数据并没有直接给出检查的时

间，所以首先需要提取出检查流水号的前 8 位表示日期的数字，接着分别算出每位患者每次检查与发病的时间间隔和这次检查的血肿体积，这样一共得到了 336 组数据。
具体的解题思路如图 4.1.1 所示：




图 4.1.1 思路流程图

首先使用了 SVR 进行拟合，时间间隔的最小单位为 24 小时，结果如图 4.1.2 所示：




图 4.1.2 基于 SVR 回归的拟合曲线

可以发现拟合的准确度很低，经过分析认为时间间隔的最小单位为 24 个小时可能会导致误差较大，接着将时间间隔改为一小时，使用线性多项式回归进行拟合，结果如图 4.1.3 所示：




图 4.1.3 基于线性多项式回归的拟合曲线

可以发现结果仍然很不好，所以导致拟合准确度差的不仅仅是因为一些常规的问题，要从问题本身进行深入分析。

之前拟合所使用的 336 组数据，是将 100 为患者的数据全部打乱，以时间间隔的大小进行从小到大的排列，进行拟合的。这样会忽略患者身体性能的个体差异，所以用不同的颜色将不同的患者进行区分，使用二次多项式回归^[5]进行拟合，结果如图 4.1.4 所示：




图 4.1.4 基于二次多项式回归的拟合曲线

可以发现结果相较于前两种拟合方法的准确度有所改善，但是仔细观察后发现 1500 小时以后的点较分散，跨度也较大，可能是因为脑卒中患者发病 1500 小时后病情趋于稳定，所以很少进行检查或很久才会再次检查，所以研究 1500 小时以后的数据意义不大。

基于以上分析，去除了 1500 小时以后的数据，使用四次多项式回归^[6]进行拟合，结

果如图 4.1.5 所示：




图 4.1.5 基于四次多项式回归的拟合曲线

经过多次改进，可以发现这次的拟合效果比较理想，准确的描述了患者水肿体积随时间进展的趋势，曲线的具体方程如下：

$$y = -20871.15440719664 \times x^4 + 66569.53374701788 \times x^3 - 79347.15160697054 \times x^2 + 35228.99441974774 \times x + 26151.139655172425$$

从拟合的水肿体积随时间进展的曲线可以看出，脑卒中患者在发病后 300 小时之内水肿体积会持续增加，所以发病后的 300 小时之内为脑卒中患者的危险期，需要进行多次复查，监控水肿体积的变化，及时采取治疗手段以防止病情的进一步恶化。发病后 300 小时之后，水肿体积会持续降低，所以对水肿患者来说，发病后的 300 小时之内非常关键。

4.2 子问题 b

4.2.1 问题分析

为了准确的根据个性差异将人群进行分类，需要考虑很多因素，例如：相关疾病史、吸烟史、饮酒史、年龄、性别等。聚类分析是一种定量方法，在分类时往往更客观，将从数据分析的角度更准确更细致的进行分类。

经过子问题 a 的探索：使用时间间隔的最小单位划分为每小时、用不同的颜色区分不同的病人、去掉 1500 小时以外的数据等改进方法后，使用四次多项式回归来拟合水肿体积随时间进展的曲线结果较为理想。所以该问题可以使用同样的改进方法和拟合方法。

4.2.2 模型的建立与求解

K-means 聚类分析术语一种迭代优化的聚类分析算法^[7]，它将数据集划分为 K 个簇，这里的 K 值需要先人为设定，本题将 K 值设定为 4。使每个样本到其所属簇的中心的距离之和最小。在每次迭代中，会重新计算每个样本所属的簇，并更新簇的中心，直到簇的中心点不再发生变化或达到最大迭代次数为止。最后使每个数据点都属于离自己最近的簇，簇的中心是所有数据点的平均值^[8]。此算法使用的距离为欧几里得距离：

$$d(x, y) = \left[\sum_{k=1}^8 |x_k - y_k|^2 \right]^{\frac{1}{2}}$$

具体的步骤为：首先选择 4 个数据点作为初始的簇中心，将每个数据点分配到距离其最近的簇中心；接着根据分配的数据点更新簇中心，这是通过计算属于每个簇的数据点的平均值来实现的；最后不断重复以上步骤，直到簇中心不再发生变化或者达到预定的迭代次数。也要注意防止该算法陷入局部最优解。

患者的分类情况如表 4.2.1 所示：

表 4.2.1 患者分类情况

分类	ID
第一类	sub001、sub002、sub003、sub005、sub006、sub007、sub008、sub011、sub013、sub014、sub015、sub016、sub017、sub018、sub019、sub020、sub021、sub022、sub025、sub026、sub028、sub029、sub030、sub031、sub033、sub034、sub035、sub036、sub037、sub038、sub039、sub040、sub041、sub042、sub043、sub044、sub046、sub047、sub048、sub049、sub050、sub051、sub053、sub054、sub055、sub056、sub057、sub060、sub061、sub062、sub064、sub065、sub066、sub067、sub069、sub070、sub073、sub074、sub075、sub079、sub080、sub083、sub085、sub086、sub088、sub089、sub090、sub091、sub095、sub096、sub097、sub099、
第二类	sub010、sub012、sub023、sub024、sub032、sub045、sub063、sub068、sub078、sub082、sub084、sub093、sub094、sub100
第三类	sub004、sub058、sub059、sub087
第四类	sub009、sub027、sub052、sub071、sub072、sub076、sub077、sub081、sub092、sub098

第一类患者水肿体积随时间进展曲线如图 4.2.1 所示：




图 4.2.1 第一类患者水肿体积随时间进展曲线

第一类患者发病后的 250 小时内水肿体积呈逐步增长的趋势，过了这段时间后水肿体积开始下降，在发病 1150 小时左右后，水肿体积变为零。所以第一类的脑卒中患者只要在发病后 250 小时内小心照顾身体，及时参与治疗，一般疾病不会发生恶化。

第二类患者水肿体积随时间进展曲线如图 4.2.2 所示：




图 4.2.2 第二类患者水肿体积随时间进展曲线

第二类患者的情况很危险，在发病后的 1000 小时内，水肿体积会随时间急速增长，在这段时间内患者一定要多做检查，及时治疗，因为在这段时间内病情恶化的可能性会非常大。只要度过了这段时间，水肿体积就会很快的降低到 0。因此对于这类患者发病后的 1000 小时内的这段时间非常关键。

第三类患者水肿体积随时间进展曲线如图 4.2.3 所示：




图 4.2.3 第三类患者水肿体积随时间进展曲线

第三类患者只有在发病后 48 小时内水肿体积会增长一点，但影响不大。之后就会随着时间的增加逐渐降低，但这类患者的水肿体积很难清零，这是需要特别注意的地方，需要积极的采取相关的治疗。

第四类患者水肿体积随时间进展曲线如图 4.2.4 所示：




图 4.2.4 第四类患者水肿体积随时间进展曲线

第四类患者的危险期也比较长，在发病后的 600 小时内，水肿体积都会持续增加，需要持续的监控水肿体积变化并采取相关治疗。600 小时后，水肿体积会急速减少至零，即危险期度过。

4.3 子问题 c

4.3.1 问题分析

问题的目标是分析脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经这 7 种不同的治疗方法对水肿进展模式的影响，可以使用梯度提升机模型来进行分析。

定义脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经作为特征，水肿进展模式作为目标。然后使用梯度提升机模型，用训练集对其进行训练。接着使用测试集对模型进行预测，并输出关于模型好坏的分类报告，通过优化使模型的准确度达到理想状态，这样可以较准确的得出这 7 个治疗方法分别对水肿体积进展模式影响程度的大小。

4.3.2 模型的建立与求解

梯度提升机是一种机器学习算法，基于集成学习的思想，通过结合多个决策树构建一个较强的学习器。

其基本思想是，进行每一次迭代时，都会训练一个新的模型，来预测前一次迭代的模型的残差也即真实值与预测值之差。因此每一次迭代都在尝试纠正前一次迭代的错误。在训练完成后，最后的模型是所有单个模型的加权和，这样准确度就大大提升了。

首先计算模型的均方误差和损失对预测值的导数，使用一个新的决策树来拟合这个预测残差。将新的模型加入到当前模型中，通过不断迭代，将前一轮模型的预测结果与实际值之间的差异作为新一轮模型的目标，来逐步减小预测误差，提升模型的准确性。

不同的治疗方法对水肿体积进展模式的影响程度如图 4.3.1 所示：




图 4.3.1 不同治疗方法对水肿体积进展模式的影响程度（优化前）

优化后的 7 种治疗方法对水肿体积进展模式的影响程度如图 4.3.2 所示：




图 4.3.2 不同治疗方法对水肿体积进展模式的影响程度（优化后）

结果显示：7 种治疗手段对治疗和缓解水肿体积的有效程度从大到小排序为：降压治疗、营养神经、止血治疗、镇静镇痛治疗、降颅压治疗、止吐护胃、脑室引流。

不同的治疗方法对缓解水肿体积的有效程度也不相同，其中降压治疗是出血性脑卒中治疗的重要一环。降压治疗通过降低血压来减少脑部出血量，从而减轻脑损伤的程度，降低脑水肿发生的概率。但是在实际治疗过程中，也要注意血压降低的程度，如果血压降得过低，就有可能导致患者脑部供血出现不足的状况，反而会加重脑水肿的出现。因此，降压治疗也需要谨慎进行，可以根据患者的自身情况确定合适的降压方案。其次，营养神

经这一环节也非常重要，营养神经可以通过改善脑细胞的代谢，提供适当的营养直接，并促进脑部神经功能的恢复，从而减轻患者脑水肿的症状。同时营养神经也可以维持免疫功能、促进伤口的愈合、预防并发症的发生，使患者能够更好的恢复身体健康。面对不同的患者，在治疗过程中需要根据病人的情况制定合理的治疗方案，从而为患者提供更好的医疗服务。

4.4 子问题 d

4.4.1 问题分析

由于血肿体积和水肿体积两个变量分布呈严重非正态且 7 种治疗方法为非连续变量，所以导致使用皮尔逊相关系数^[9]进行分析时结果误差很大，而斯皮尔曼相关系数可以完美解决以上问题。

斯皮尔曼相关系数^[10]具有非常优秀的应用场景，适用于分析两个变量之间的相关关系且有等级变量性质具有线性关系的资料。它首先将两个变量的观察值转换为等级，然后计算等级之间的相关性来衡量变量之间的关系。该方法的主要原理是将原始数据转换为等级数据，其中最小的观察值等级为 1，依此类推，最大的观察值等级为 n ，其中 n 是总观察数。斯皮尔曼相关系数是通过计算等级之间的排名差异来确定。

4.4.2 模型的建立与求解

斯皮尔曼相关系数，是秩相关系数的一种。“秩”，即秩序，是一种顺序或排序，根据变量在数据内的位置进行计算。

与皮尔逊相关系数相比，斯皮尔曼相关系数没有那些限制，比如要符合正态分布、样本容量要超过一定数量(比如 30 个)，除此之外，斯皮尔曼相关系数不受离群值影响，适用于非线性。对于斯皮尔曼相关系数，我们不需要关心数据如何变化，符合什么样的分布，只需要关心每个变量对应数值的位置。如果两个变量的对应值，在各组内的排列顺位是相同或类似的，则具有显著的相关性。

斯皮尔曼相关系数的计算公式为：

$$r_s = 1 - \frac{6 \sum_{i=1}^{160} d_i^2}{160^3 - 160}$$

斯皮尔曼相关系数是一个介于-1和1之间的值，表示两个变量之间的线性关系强度和方向。如果相关系数为正数，则两个变量呈正相关关系，即随着一个变量的增加，另一个变量也会增加；如果相关系数为负数，则两个变量呈负相关关系，即随着一个变量的增加，另一个变量会减少；如果相关系数为 0，则两个变量之间不存在线性关系。相关系数的绝对值越大，说明两个变量之间的相关性越强。

一般将相关程度分为 6 个等级。若 $r_s = 0$ ，则没有相关性；若 $0 < r_s \leq 0.2$ ，则相关性等级为：很弱；若 $0.2 < r_s \leq 0.4$ ，则相关性等级为：弱；若 $0.4 < r_s \leq 0.6$ ，则相关性等级为：中等；若 $0.6 < r_s \leq 0.8$ ，则相关性等级为：强；若 $0.8 < r_s \leq 1$ ，则相关性等级：很强。

将血肿体积、水肿体积、脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经这 9 个变量两两之间进行斯皮尔曼相关系数分析，得到的结果如下图 4.4.1 所示：




图 4.4.1 变量之间的斯皮尔曼相关系数热力图

首先来分析血肿体积与水肿体积之间的关系，它们之间的斯皮尔曼相关系数为 0.7，可见相关程度很高，说明血肿体积的增加和减少也会导致水肿体积的增加和减少，反之亦然。

其次来分析血肿体积与脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经这 7 种治疗方法的相关程度。根据斯皮尔曼相关关系数，得出不同治疗方法对于缓解和治疗血肿体积扩张的有效程度从高到低分别为：降颅压治疗、脑室引流、止血治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经。

最后来分析水肿体积与脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经这 7 种治疗方法的相关程度。根据斯皮尔曼相关关系数，得出不同治疗方法对于缓解和治疗水肿体积扩张的有效程度从高到低分别为：降颅压治疗、脑室引流、营养神经、止血治疗、降压治疗、止吐护胃、镇静镇痛治疗。

降颅压治疗对治疗和缓解血肿、水肿扩张的效果最好，有更好的医疗条件时，建议不要使用营养神经对血肿扩张患者进行治疗，不要使用镇静镇痛治疗对水肿扩张患者进行治疗，因为它们之间的斯皮尔曼相关系数呈负相关，但是相关程度很弱，所以也不会产生很大的负面影响。

通过综合分析，建议脑卒中患者可以同时使用多种治疗手段进行治疗水肿和水肿扩张，这样的效果要比单个的治疗手段效果要好得多。

5 问题三模型的建立与求解

5.1 子问题 a

5.1.1 问题分析

该问题需要根据前 100 个患者的个人史、疾病史、发病相关和首次影像结果来构建预测模型，预测患者 90 天 mRS 评分。也即将患者预后的身体状况进行量化，通过建立模型来预测患者预后的身体状况，并分为 7 个类型。

这类问题同时适用于随机森林模型和支持向量机（SVC）^[11]模型来预测，所以可以通过比较模型的相关指标和灵敏度来选出准确度最高的模型。

5.1.2 数据预处理

要预测患者预后的身体状况基于的因素有很多，数据类型不一，需要先进行处理。部分数据是文字形式需要量化，例如：性别，所以将男生设置为 1，女生设置为 0；有些数据是组合形式，需要进行分割，例如：血压，所以将血压字段的数据分割为高压和低压；不同类型数据的量纲不同，例如：血肿体积与血肿体积的位置占比，所以对数据进行了归一化，这样模型不会过于依赖某些特征，变得更加稳定，也可以减少模型对数据绩的依赖程度，从而提高模型在未知数据上的泛化能力。

5.1.3 模型的建立与求解

基于患者的多种相关因素，分别使用了随机森林和支持向量机（SVC）对患者预后的身体状况进行预测，并分类。通过对比两个模型的混淆矩阵、准确率、召回率等指标对它们进行评估，结果显示支持向量机（SVC）优于随机森林^[12]。

支持向量机分类（SVC）模型的目标是找到一个最优超平面，将不同的数据点分开，这个最优超平面是根据训练数据中的特征和相应的标签来得到的。具体的，首先进行数据预处理：特征缩放、去除异常值、处理缺失值等。其次开始训练模型，使用支持向量机来训练模型，通过选择适当的核函数和参数，使得训练后的模型能够最大程度地接近最优超平面。接着确定决策边界，在训练模型之后，该模型会根据训练的数据生成一个决策边界，这个决策边界是根据支持向量和核函数确定的。最后来分类新数据，当有新的数据点进入时，支持向量机分类（SVC）模型会根据已经训练好的模型，将新的数据点分类到相应的类别中。通过最大化分类间隔、最小化经验风险和正则化项，该模型可以获得最优的分类效果。支持向量机（SVC）的核心公式为：

$$f(x) = W^T \times X + b$$

其中， $f(x)$ 是判别函数， W 是权重向量， X 是输入特征向量， b 是偏置项。这个公式的意义是，通过将输入特征向量 X 与权重向量 W 进行线性组合，再加上偏置项 b ，得到一个判别函数 $f(x)$ ，用于将样本进行分类。

在训练过程中，模型会不断尝试，直到找到一个最优的权重向量 W 和偏置项 b ，使得判别函数 $f(x)$ 能够将训练数据中的样本正确分类。显然，模型的训练过程是通过求解一个二次规划问题来实现的，这个二次规划问题的目标函数是最大化分类间隔、最小化经验风险和正则化项之和。通过求解这个二次规划问题，模型可以获得最优的权重向量 W 和偏置

项**b**，并得到一个最优的分类器。

模型会根据已经训练好的模型，将新的样本点分类到相应的类别中。也即模型会计算每个样本点到最优超平面的距离，并根据判别函数 $f(x)$ 的值将样本点分类到相应的类别中。

预测患者 90 天 mRS 评分见支撑材料，这 7 种类型的患者分布情况如图 5.1.1 所示：




图 5.1.1 患者预后身体状态分布图

预测的结果显示：19%的患者预后没有症状，没有残疾；22%的患者预后没有明显的残疾，能够独立的进行日常活动；17%的患者预后轻度残疾，能够自理，但在活动中存在一些限制；18%的患者预后中度残疾，需要一定程度的照顾和帮助，但能够坐立或站立；8%的患者预后中重度残疾，需要全天候照顾和帮助，无法行走或自理；13%的患者预后完全依赖他人，不能进行任何活动；3%的患者会死亡。所以大概有一半的患者预后良好，基本不影响身体健康和正常生活，但是预后出现严重健康事故的比例也不低，所以对脑卒中患者的预后相关问题要非常重视，积极地配合治疗、改善生活习惯、戒烟戒酒都会患者预后身体健康的几率大大增加。

5.2 子问题 b

5.2.1 问题分析

该问题需要根据前 100 个患者所有已知临床、治疗、首次和随访影像结果来构建预测模型，预测患者 90 天 mRS 评分。也即将患者预后的身体状况进行量化，通过建立模型来预测患者预后的身体状况，并分为 7 个类型。

与子问题 a 相比，子问题 b 增加了随访的影响结果，所以可能问题的分不会完全不一样。但是这类问题同样适用于随机森林模型和支持向量机 (SVC) ^[11] 模型来预测，所以可以通过比较模型的相关指标和灵敏度来选出准确度最高的模型。

5.2.2 模型的建立与求解

基于和患者相关的多种因素，分别使用了随机森林和支持向量机 (SVC) 对患者预后的身体状况进行预测，并分类。通过对比两个模型的混淆矩阵、准确率、召回率等指标对它们进行评估，结果显示随机森林^[12]优于支持向量机 (SVC)。

随机森林是一种集成学习算法，通过将多棵树集成起来提高分类和预测的准确性。它的基本单元是决策树，随机森林是一个包含多个决策树的分类器，并且其输出的类别是由个别树输出的类别的众数决定的。

随机森林是先进行随机抽样，抽出和数据集同样数量的样本。接着循环上面的操作数

次，形成数个这样的样本。然后对每个样本，随机选取少量特征，选取的特征数要远远小于总的特征数，然后在里面再选取最优特征来对应决策树。所有决策树通过投票的方式进行决策，组成随机森林。它的核心思想就是通过多个决策树对数据进行分类，最后用所有决策树得出的结果进行投票，得到最终的分类结果。

预测患者 90 天 mRS 评分见支撑材料，这 7 种类型的患者分布情况如图 5.2.1 所示：




图 5.2.1 患者预后身体状态分布图（增加随访结果后）

预测的结果显示：5%的患者预后没有症状，没有残疾；2%的患者预后没有明显的残疾，能够独立的进行日常活动；22%的患者预后轻度残疾，能够自理，但在活动中存在一些限制；39%的患者预后中度残疾，需要一定程度的照顾和帮助，但能够坐立或站立；9%的患者预后中重度残疾，需要全天候照顾和帮助，无法行走或自理；21%的患者预后完全依赖他人，不能进行任何活动；2%的患者会死亡。由上图可以看出，22%的患者 mRS 评分为 2，39%的患者 mRS 评分为 3，均可能有轻度或中度残疾，并且生活上会受到一些限制，出血性脑卒中对人们的生活状态影响比较大，因此人们需做好出血性脑卒中的预后处理，以便使病人身体恢复的更好。

5.3 子问题 c

5.3.1 问题分析

由于出血性脑卒中患者的预后（90 天 mRS）与患者的个人史、疾病史、治疗方法和影像特征，例如血肿和水肿体积、位置、信号的强度特征、形状特征等，它们都具有一定的关系，接下来主要通过使用文字挖掘技术深入地分析患者预后与个人史、疾病史等相关特征之间的相关关系，并根据此相关关系，为医生和医护人员提出相关临床决策和建议，给患者提供更好的医护治疗。

5.3.2 模型的建立与求解

出血性脑卒中患者的预后与多个因素 相关，包括个人史、疾病史、治疗方法以及血肿和水肿的体积、位置、信号强度特征和形状特征等。针对其相关关系提出临床相关建议：

预后与个人史方面^[13]：患者的年龄、性别、基础健康状况（如糖尿病、高血压等）和生活习惯（如饮食、运动等）均可影响出血性脑卒中患者预后。若有高血压病史者，可因血压控制不佳而引起脑出血复发而影响预后。提示发病前应主动控制基础疾病和改善生活习惯才能减少脑卒中的发生。

疾病史与预后方面^[14]：对于出血性脑卒中患者，如果他们有既往的脑卒中病史，那

么再次发生脑卒中的风险可能会增加。此外，如果患者在短暂性缺血发作后未能及时得到治疗，可能会进展为完全性脑卒中。因此，对于有既往脑卒中或短暂性脑缺血病史的患者，应该积极干预，以防止病情恶化。

预后与治疗方法方面^[15]：治疗方法包括手术治疗和药物治疗等。针对脑出血量大的患者，通过开颅手术或者微创手术等手术治疗可以有效地帮助患者清除血肿、降低其颅内压、降低死亡率等。在药物治疗方面，早期使用止血药、降低颅内压力的药物和神经保护剂均有可能改善患者的预后。中西医结合可以更好地促进患者康复。建议医生根据患者的病情和自身经验选择合适的治疗方法。

预后与血肿/水肿体积和位置方面^[16]：血肿/水肿体积较大、位置关键（如脑干）可能影响患者的预后。并且通过研究可以发现，血肿体积大于 30ml 或水肿范围超过脑室的 1/3 的患者，他们的预后情况较差。针对此类情况，应在治疗原发病的同时，积极采取脱水、利尿等措施减轻患者的脑水肿情况，预防脑疝。

预后与信号强度特征方面^[17]：MRI 成像中的信号强度可反映出血肿的新鲜程度和含水量。对于不同信号强度的血肿进行分类，并对患者采取针对性的治疗，这可以有助于改善患者的预后。建议在 MRI 检查中关注信号强度特征，为后续治疗提供参考。

预后与血肿/水肿形状特征方面：血肿的形状也与预后有关。血肿形态不规则、存在分隔或多房结构可能会使治疗更加困难，造成患者预后不良。针对此类患者，可能需要更加细致的影像学评估和患者的治疗计划。在治疗过程中，建议根据血肿的形状特征制定针对性的治疗方案。

出血性脑卒中发生后，患者会因为头疼的发生、肢体神经性功能的缺失和对病情的较多的关注，大部分患者容易出现失眠等睡眠障碍，同时引起病人的负情绪增长，造成饮食障碍。出血性脑卒中患者脑出血后身体会出现一系列的应激反应，迫使兴奋交感神经系统占据主导地位，使得身体机能代谢加快，身体消耗增加；处于应激状态下的身体机能容易导致患者肠胃功能紊乱、肠胃的血液动力学改变，进而影响病人本身的主动进食兴趣，从而会使得出血性脑卒中患者的营养状况恶化。因此营养支持对出血性脑卒中患者也十分重要。

临床上对出血性脑卒中患者的治疗决策可考虑如下因素：

1、病情评估与诊断：病人在入院时立即对病人病情作细致的评价，其中包括对意识状态、瞳孔变化和生命体征的评价；利用头部 CT 和其他影像学检查明确出血的位置、出血量及有无脑疝的形成；结合心电图、血常规及凝血功能等实验室检查评价病人的身体状况及出血原因。

2、手术决策：依据病人的病情评估结果及相关影像学的影像结果决定患者是否需要手术；对于出血量较多，有可能形成脑疝的病人要尽早手术，可采用开颅手术的手术方式，也可采用立体定向穿刺置管引流手术；针对出血量少的病人可采用药物保守治疗并观察其变化情况，适时调整治疗方案。

3、药物治疗：可以使用甘露醇之类的脱水药降低颅内压和减轻脑水肿；应用酚磺乙胺等止血药物，防止患者出血进一步加重；根据疾病的需要采用降压药和抗癫痫药物进行协助治疗；应用营养神经药物等促进脑功能恢复。

4、康复治疗：病人病情平稳之后需及早接受康复治疗；康复训练包括肢体功能康复、语言能力康复、认知功能康复等。针对病人具体情况，制订个性化康复计划；同时鼓励病人主动参与康复治疗、建立自信、积极面对疾病。

6 模型评价与推广

6.1 模型优点

(1) 模型查阅中阅读大量文献，对不同模型的不同特点进行结合，模型真实可靠，有迹可循，实用性高。

(2) 问题相较于实际问题做了适当简化，便于理解，便于后续进一步研究。

(3) 多因素 Logistic 回归模型可以解释多个自变量和因变量之间的复杂关系，并且可以通过使用多个自变量，可以更准确地预测因变量的值，具有更高的预测精度。

(4) 斯皮尔曼相关系数在处理含异常值的数据时较为稳健。

(5) 梯度提升机具有提升模型性能、处理各种类型数据、抗噪、高精度等优点，可以更好的预测和处理数据。

6.2 模型缺点

(1) 问题相较于实际问题作了适当简化，运用到实际问题中还需要考虑其他参数的影响。

(2) 多因素回归模型计算复杂度高，并且随着自变量数量的增加，多因素回归模型的参数数量呈指数级增长，模型的训练和预测时间会大大增加。

(3) 样本量较小时，斯皮尔曼相关系数的计算结果可能不稳定。

6.3 展望

如果在时间允许的情况下会更好地完成论文问题，使问题的解答更为充分，会进一步探索全体患者水肿体积随时间的变化曲线，同时结合更多的数据去改进模型；基于问题 3 创建一个模型根据病人的疾病史、发病相关特征及影像结果可以直接得出患者的 mRS 结果，并给出专业的相关临床建议，更好的解决出血性脑卒中的临床智能诊疗等相关问题。

参考文献

- [1] 李倩,刘芸宏,吴晓慧等.基于决策树和 Logistic 回归预测出血性脑卒中手术后医院感染风险[J].中华医院感染学杂志,2021,31(23):3556-3561.
- [2] 张冉,赵琥,侯林等.基于 MLP 神经网络的海上固井泵故障诊断方法[J].自动化与仪器仪表,2022(09):54-57.DOI:10.14016/j.cnki.1001-9227.2022.09.054.
- [3] 黄梅.基于可信执行环境的公平隐私联邦梯度提升决策树系统研究[D].广西师范大学,2023.DOI:10.27036/d.cnki.ggxsu.2023.001799.
- [4] 周弘毅,夏磊.基于随机森林算法的电气设备异常振动识别方法[J].科学技术创新,2023(22):7-10.
- [5] 吕冠颖,刘畅,何环莎等.基于 N 阶多项式回归方程的 RMR 分级方法优化[J].矿冶,2023,32(04):6-11.
- [6] 胡志阳,谭佳源,刘国华.一种基于白平衡和多项式回归结合的中医望诊图像校正算法[J].南开大学学报(自然科学版),2022,55(04):25-28+37.
- [7] 伍信怡,汪璐,史富存.基于 K-means 聚类分析法的三峡货物分类研究[J].中国水运,2021(06):97-99.DOI:10.13646/j.cnki.42-1395/u.2021.06.033.
- [8] 宋争艳,王振坤,尹奕等.基于 K-means 聚类分析的任务定价方案[J].实验科学与技术,2019,17(02):51-56.
- [9] 程娟娟.高校科研与教学关系实证研究——基于皮尔逊相关系数的分析[J].中国高校科技,2022(10):46-52.DOI:10.16209/j.cnki.cust.2022.10.016.
- [10] 贾科,杨哲,魏超等.基于斯皮尔曼等级相关系数的新能源送出线路纵联保护[J].电力系统自动化,2020,44(15):103-111.
- [11] 高加琼,魏霖静.基于最小二乘及分类向量机的空气调节器故障检测[J].沈阳工业大学学报,2016,38(03):326-330.
- [12] 彭晨.基于机器学习算法的缺血性脑卒中患者预后影响因素及预测研究[D].南昌大学,2021.DOI:10.27232/d.cnki.gnchu.2021.001034.
- [13] 黄瑞瑜,李云峰,黄俊杰.影响进展性缺血性脑卒中患者预后的 Logistics 分析[J].深圳中西医结合杂志,2019,29(15):11-12.DOI:10.16458/j.cnki.1007-0893.2019.15.005.
- [14] 钱利娜,张蒙梦.安全管理模式护理在改善老年急性出血性脑卒中偏瘫患者预后生存质量的应用研究[J].中国药物与临床,2020,20(06):1004-1005.
- [15] 黄杉,鲁艳梅,刘姗姗等.出血性脑卒中病人早期康复护理干预研究进展[J].全科护理,2022,20(11):1487-1490.
- [16] 宋杨君.CT 平扫影像学征象预测自发性脑出血患者早期血肿扩张的临床价值分析[J].中国 CT 和 MRI 杂志,2021,19(11):20-22.
- [17] 从祥丰.中国 11 省队列人群脑卒中及其亚型发病状况及影响因素研究[D].中国疾病预防控制中心,2021.DOI:10.27511/d.cnki.gzyyy.2021.000073.

附录

附录一：第一问 b 题部分代码

```
#数据预处理
target='是否发生血肿扩张'
#处理性别, '男', 1, '女', 0
df5['性别'] = df5['性别'].replace('男', 1)
df5['性别'] = df5['性别'].replace('女', 0)

#将血压分为高低血压
df5['高血压']=0
df5['低血压']=0
for i in range(len(df5)):
    df5['高血压'][i],df5['低血压'][i]=df5['血压'][i].split('/')

#选择特征
features=['ID','高血压','低血压','年龄','性别','脑出血前 mRS 评分','高血压病史','卒中病史','糖尿病史','房颤史','冠心病史','吸烟史','饮酒史','发病到首次影像检查时间间隔','血压','脑室引流','止血治疗','降颅压治疗','降压治疗','镇静、镇痛治疗','止吐护胃','营养神经','original_shape_Elongation','original_shape_Flatness','original_shape_LeastAxisLength','original_shape_MajorAxisLength','original_shape_Maximum2DDiameterColumn','original_shape_Maximum2DDiameterRow','original_shape_Maximum2DDiameterSlice','original_shape_Maximum3DDiameter','original_shape_MeshVolume','original_shape_MinorAxisLength','original_shape_Sphericity','original_shape_SurfaceArea','original_shape_SurfaceVolumeRatio','original_shape_VoxelVolume','NCCT_original_firstorder_10Percentile','NCCT_original_firstorder_90Percentile','NCCT_original_firstorder_Energy','NCCT_original_firstorder_Entropy','NCCT_original_firstorder_InterquartileRange','NCCT_original_firstorder_Kurtosis','NCCT_original_firstorder_Maximum','NCCT_original_firstorder_MeanAbsoluteDeviation','NCCT_original_firstorder_Mean','NCCT_original_firstorder_Median','NCCT_original_firstorder_Minimum','NCCT_original_firstorder_Range','NCCT_original_firstorder_RobustMeanAbsoluteDeviation','NCCT_original_firstorder_RootMeanSquared','NCCT_original_firstorder_Skewness','NCCT_original_firstorder_Uniformity','NCCT_original_firstorder_Variance',
'HM_volume','HM_ACA_R_Ratio','HM_MCA_R_Ratio','HM_PCA_R_Ratio','HM_Pons_Medulla_R_Ratio','HM_Cerebellum_R_Ratio','HM_ACA_L_Ratio','HM_MCA_L_Ratio','HM_PCA_L_Ratio','HM_Pons_Medulla_L_Ratio','HM_Cerebellum_L_Ratio','ED_volume','ED_ACA_R_Ratio','ED_MCA_R_Ratio','ED_PCA_R_Ratio','ED_Pons_Medulla_R_Ratio','ED_Cerebellum_R_Ratio','ED_ACA_L_Ratio','ED_MCA_L_Ratio','ED_PCA_L_Ratio','ED_Pons_Medulla_L_Ratio','ED_Cerebellum_L_Ratio']

#df6 为前 100 名患者
df6=df5[features][1:100]
df6[target]=df5[target][1:100]
df6[target]
df6[target]=df6[target].fillna(0)#保证模型正常预测
```

```

\
#定义模型 1↵
lr = LogisticRegression()↵
↵
# 使用训练集对模型进行拟合 1↵
lr.fit(X_train, y_train)↵
↵
# 使用测试集进行预测 1↵
y_pred = lr.predict(X_test)↵
↵
# 将预测结果转换为概率值 1↵
y_pred_proba = lr.predict_proba(X_test)[:, 1]↵
y_pred_proba=y_pred_proba.reshape(-1,1)↵
↵
#对比预测值和实际值 1↵
print(y_test,y_pred_proba)↵
↵
↵
# 定义要搜索的参数空间 1↵
param_grid = {'C': [0.1, 1, 10, 100], 'penalty': ['l1', 'l2', 'elasticnet'], 'max_iter': [500, 1000, 1500],
'solver': ['lbfgs', 'liblinear', 'saga', 'sag', 'newton-cg'], 'tol': [1e-4, 1e-5]}↵
↵
# 使用 GridSearchCV 进行交叉验证 1↵
grid_search = GridSearchCV(lr, param_grid, cv=5)↵
grid_search.fit(X_train, y_train)↵
↵
# 输出最佳参数 1↵
print("最佳参数: ", grid_search.best_params_)↵
print("最佳得分: ", grid_search.best_score_)↵
↵
↵
# 使用测试集进行预测 1↵
y_pred = grid_search.predict(X_test)↵
↵
# 将预测结果转换为概率值 1↵
y_pred_proba = grid_search.predict_proba(X_test)[:, 1]↵
y_pred_proba=y_pred_proba.reshape(-1,1)↵
↵
print(y_test,y_pred_proba)↵

```

附录二：第二问 a 题部分代码

```
←
# 将指定列的数据转换为日期类型←
df1['t'] = pd.to_datetime(df1['t'])←
df1.t←
# 保存转换后的 Excel 文件←
df1.to_csv('E:/data1.csv', index=False)←
←
#去掉空值←
df1=df1.dropna()←
←
# 创建坐标轴←
ax = plt.gca()←
←
# 设置 x 轴和 y 轴的刻度←
ax.set_xticks([1, 2, 3, 4, 5,6,7,8,9])←
ax.set_yticks([0,20000, 40000, 60000, 80000, 100000,120000,140000,160000])←
←
#将多个点放入一个坐标轴←
df2=df1[df1['id']=='sub1']←
df3=df1[df1['id']=='sub2']←
df4=df1[df1['id']=='sub3']←
df5=df1[df1['id']=='sub4']←
# df6=df1[df1['id']=='sub5']#←
df7=df1[df1['id']=='sub7']←
←
←
plt.scatter(df2.t,df2.v)←
plt.scatter(df3.t,df3.v)←
plt.scatter(df4.t,df4.v)←
plt.scatter(df5.t,df5.v)←
# plt.scatter(df6.t,df6.v)←
plt.scatter(df7.t,df7.v)←
←
←
plt.show()←
←
```

附录三：第二问 b 题部分代码

```
#聚类代码
#
#数据处理
#处理性别, '男', 1, '女', 0
df1['性别'] = df1['性别'].replace('男', 1)
df1['性别'] = df1['性别'].replace('女', 0)
#
#将血压分为高低血压
df1['高血压']=0
df1['低血压']=0
for i in range(len(df1)):
    df1['高血压'][i],df1['低血压'][i]=df1['血压'][i].split('/')
#
#创建用于聚类的特征列
features=['高血压','低血压','年龄','性别','脑出血前 mRS 评分','高血压病史','卒中病史','糖尿病史','房颤史','冠心病史','吸烟史','饮酒史']
#
# 对数据进行标准化,标准话后就会转化为 np 数组
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df1[features][:100])
# 将数据集前 100 个样本的特征作为聚类的特征
#
# 定义参数
#可以通过设置 init 参数为 'k-means++' 来避免修改数据的索引
kmeans = KMeans(n_clusters=4,init='k-means++')
#
# 聚类
kmeans.fit(X_scaled)
#
# 输出每个样本所属的簇
print(kmeans.labels_.reshape(-1,1))
#
# 输出每个簇的中心点坐标
print(kmeans.cluster_centers_)
#
#直接使用最好的四次多项式拟合
df1=df1.dropna()
df2=df2[:100]
df4=df4[:100]
#
#df1,df2,df4 根据聚类结果分为四类
```

```

df11=df1[df1['聚类结果']==0]#第一类
df12=df1[df1['聚类结果']==1]#第二类
df13=df1[df1['聚类结果']==2]#第三类
df14=df1[df1['聚类结果']==3]#第四类
↵

df21=df2[df2['聚类结果']==0]#第一类
df22=df2[df2['聚类结果']==1]#第二类
df23=df2[df2['聚类结果']==2]#第三类
df24=df2[df2['聚类结果']==3]#第四类
↵

df41=df4[df4['聚类结果']==0]#第一类
df42=df4[df4['聚类结果']==1]#第二类
df43=df4[df4['聚类结果']==2]#第三类
df44=df4[df4['聚类结果']==3]#第四类
↵

#将附表的检查编号和检查时间转换成 dataframe
#df11,df21,df41 进行处理
ls11=[]#ID
ls21=[]#重复次数
ls31=[]#time
ls41=[]#code
ls51=[]#检查次数
ls61=[]#first_code
↵

for value in df41.values:
    ID = value[0]
    freq = value[1]
    for f in range(freq):
        ls11. append(ID)
        ls21. append(freq)
        ls31. append(value[f*2+2])
        ls41. append(value[f*2+3])
        ls51. append(f'第{f}次检查')
        ls61. append(value[3])

df41 = pd.DataFrame({'ID' :ls1, 'first_code':ls6, '重复次数':ls2, 'code':ls4, 'time':ls3, '检查次数':ls5})
df41['code'] = df41['code'].astype('int64')#转化数据类型
ls=[]
for j in df11['入院首次影像检查流水号']. values:#处理 df11
    code = df41[df41.code==j]['first_code'].values[0]#处理 code
    ls. append(code)
df11['入院首次影像检查流水号'] = ls#处理 df11

```



```

#每个检查离对应发病时间的间隔
Dataset1 = df21.copy()
ls = []
for code in dataset1['first_code']:
    delta = df11[df11.入院首次影像检查流水号==code][ '发病到首次影像检查时间间隔' ].values[0]
    first_code_time = df41[df41.code==code][ 'time' ].values[0]
    error_time1 = first_code_time-np.timedelta64(int(delta*60), 'm')
    ls.append(error_time1)
Dataset1['发病时间 1']= ls

Dataset1 = dataset[['time', 'ED_volume', '发病时间 1']]
Dataset1['间隔 1']=dataset['time'] - dataset['发病时间 1']
Dataset1['间隔小时 1'] =dataset['间隔 1'].dt.components.hours+dataset['间隔 1'].dt.components.days*24
Dataset1['间隔分钟']=dataset['间隔 1'].dt.components.minutes
Dataset1

#绘图以及生成残差文件
plt.figure(figsize=(16,8))
for i in dataset['发病时间 1'].unique():
    tem = dataset[dataset.发病时间==i]
    y = tem['ED_volume'].values
    x = tem['间隔小时'].values
    plt.scatter(x,y)

plt.tick_params(labelsize=14)
plt.plot(np.sort(X[:,0]),y_predict[np.argsort(X[:,0])],color='green',label='全体患者水肿体积随时间进展曲线')

# plt.savefig('问题 2\\degree=4 多项式回归结果. png', dpi=500)#保存图片
plt.legend()
plt.xlim(-100,1500)
plt.xlabel('发病至影像检查时间（单位小时）')
plt.ylabel('水肿体积')
plt.show()

#生成残差文件
df2['ED_predict'] = poly_reg.predict(dataset['间隔小时'].values.reshape(-1,1))
df2['残差']= df2['ED_predict'] -df2['ED_volume']
df5=df2.groupby('ID')['残差'].mean().to_excel('D:/数学建模/实战/E 题/竞赛发布数据/E2a/残差.xlsx')

```

附录四：第二问 c 题部分代码

```
#读取数据
df1 = pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E2c/t1.xlsx')

#处理缺省值,将只做一次检查的人去掉,因为无法判断进展
df2=df1[~df1['水肿是否扩张'].isna()]

#定义特征和目标变量
features=['脑室引流','止血治疗','降颅压治疗','降压治疗','镇静、镇痛治疗','止吐护胃','营养神经']
target='水肿是否扩张'

#将数据划分为训练集和测试集

x_train,x_test,y_train,y_test = train_test_split(df2[features], df2[target],
test_size=0.2,random_state=42)

#梯度控升机模型
#n_estimators:弱分类器(决策树)的数量,默认为 100。
#learning_rate:学习率,默认为 0.1。
#max_depth:决策树的最大深度,默认为 3。
#调节 n_estimators, learning_rate 2 个参数

#创建模型
gbm = GradientBoostingClassifier()

#使用默认参数训练模型
gbm.fit(x_train, y_train)

## 定义要搜索的参数空间
# param_grid = {'n_estimators':[100,500,800],'learning_rate':[0.1,0.01]}

## 使用 GridSearchCV 进行交叉验证
# grid_search1 = GridSearchCV(gbm, param_grid, cv=5)
# grid_search1.fit(x_train, y_train)

## 输出最佳参数
# print("最佳参数: ", grid_search.best_params1_)
# print("最佳得分: ", grid_search.best_score1_)
```

```

<
#预测测试集<
y_pred = gbm.predict(x_test)#默认参数预测<
# y_pred =grid_search.predict(x_test)#最佳参数预测<
<

#输出分类报告<
print(classification_report(y_test, y_pred))<
<

#获取特性重要性并创建一个 DataFrame<
<

feature_importances = gbm.feature_importances_<
feature_names = x_train.columns<
feature_importances_df = pd.DataFrame({<
'特性': feature_names,<
'重要性': feature_importances<
})<
<

#使用 seaborn 创建水平条形图,只显示前 10 个最重要的特性<
sorted_feature_importances_df=feature_importances_df.sort_values(by='重 要 性',ascending=False)<
top_10_features = sorted_feature_importances_df[:10]<
<

barplot = sns.barplot(x='重要性',y='特性', data=top_10_features,ci=None)<
<
<

plt.title("7 种治疗方法对水肿进展模式的影响程度")<
<

plt.xlabel('相对重要性')<
plt.show()<
<

```

附录五：第二问 d 题部分代码

```
df3['ED_volume']  
df3['HM_volume']  
vol_tre=['ED_volume','HM_volume','脑室引流','止血治疗','降颅压治疗','降压治疗','镇静、镇痛  
治疗','止吐护胃','营养神经']  
vols_tre=df3[vol_tre]  
corr = round(vols_tre.corr(method='spearman'),3)  
#绘图相关矩阵热力图  
fig=plt.figure(figsize=(14,7))  
ax1=fig.add_subplot(121)  
sns.heatmap(corr, annot=True, vmax=1,vmin=0,xticklabels=True, yticklabels=True, square=True)  
#相关性画图  
ax1.set_yticklabels(corr.columns,fontsize = 18, rotation = 360,horizontalalignment= 'right')  
ax1.set_xticklabels(corr.columns,fontsize = 18,horizontalalignment='right')  
ax1.set_title('9 个变量之间的斯皮尔曼相关系数热力图')
```

附录六：第三问 a 题部分代码

```
#数据处理
#处理性别, '男', 1, '女', 0
df5['性别'] = df5['性别'].replace('男', 1)
df5['性别'] = df5['性别'].replace('女', 0)
#将血压分为高低血压
df5['高血压']=0
df5['低血压']=0
for i in range(len(df5)):
    df5['高血压'][i],df5['低血压'][i]=df5['血压'][i].split('/')
features=[
    '高血压',
    '低血压',
    '年龄',
    '性别',
    '脑出血前 mRS 评分',
    '高血压病史',
    '卒中病史',
    '糖尿病史',
    '房颤史',
    '冠心病史',
    '吸烟史',
    '饮酒史',
    '发病到首次影像检查时间间隔',
    '脑室引流',
    '止血治疗',
    '降颅压治疗',
    '降压治疗',
    '镇静、镇痛治疗',
    '止吐护胃',
    '营养神经',
    'original_shape_Elongation',
    'original_shape_Flatness',
    'original_shape_LeastAxisLength',
    'original_shape_MajorAxisLength',
    'original_shape_Maximum2DDiameterColumn',
    'original_shape_Maximum2DDiameterRow',
    'original_shape_Maximum2DDiameterSlice',
    'original_shape_Maximum3DDiameter',
```

'original_shape_MeshVolume',
 'original_shape_MinorAxisLength',
 'original_shape_Sphericity',
 'original_shape_SurfaceArea',
 'original_shape_SurfaceVolumeRatio',
 'original_shape_VoxelVolume',

 'NCCT_original_firstorder_10Percentile',
 'NCCT_original_firstorder_90Percentile',
 'NCCT_original_firstorder_Energy',
 'NCCT_original_firstorder_Entropy',
 'NCCT_original_firstorder_InterquartileRange',
 'NCCT_original_firstorder_Kurtosis',
 'NCCT_original_firstorder_Maximum',
 'NCCT_original_firstorder_MeanAbsoluteDeviation',
 'NCCT_original_firstorder_Mean',
 'NCCT_original_firstorder_Median',
 'NCCT_original_firstorder_Minimum',
 'NCCT_original_firstorder_Range',
 'NCCT_original_firstorder_RobustMeanAbsoluteDeviation',
 'NCCT_original_firstorder_RootMeanSquared',
 'NCCT_original_firstorder_Skewness',
 'NCCT_original_firstorder_Uniformity',
 'NCCT_original_firstorder_Variance',

 'HM_ACA_R_Ratio',
 'HM_MCA_R_Ratio',
 'HM_PCA_R_Ratio',
 'HM_Pons_Medulla_R_Ratio',
 'HM_Cerebellum_R_Ratio',
 'HM_ACA_L_Ratio',
 'HM_MCA_L_Ratio',
 'HM_PCA_L_Ratio',
 'HM_Pons_Medulla_L_Ratio',
 'HM_Cerebellum_L_Ratio',

 'ED_ACA_R_Ratio',
 'ED_MCA_R_Ratio',
 'ED_PCA_R_Ratio',
 'ED_Pons_Medulla_R_Ratio',
 'ED_Cerebellum_R_Ratio',
 'ED_ACA_L_Ratio',
 'ED_MCA_L_Ratio',
 'ED_PCA_L_Ratio',

```

'ED_Pons_Medulla_L_Ratio',
'ED_Cerebellum_L_Ratio']

len(features)#长度正常 71
target='90 天 mRS'

df6=df5[features]

df6[target]=df5[target]
df6=df6.dropna()

#数据标准化 消除量纲产生的问题 1
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train1)
X_test = scaler.transform(X_test1)

# 创建 SVC 模型对象 1
Svm1 = SVC(kernel='linear', C=1.0, random_state=1)

# 在训练集上训练模型 1
Svm1.fit(X_train, y_train)

# 定义要搜索的参数空间 1
param_grid = {'C': [0.1, 1, 10, 100], 'kernel': ['linear', 'rbf', 'poly']}

# 使用 GridSearchCV 进行交叉验证 1
grid_search = GridSearchCV(svm, param_grid, cv=5)
grid_search.fit(X_train, y_train)

# 输出最佳参数 1
print("最佳参数: ", grid_search.best_params_)
print("最佳得分: ", grid_search.best_score_)

y_pred=grid_search.predict(X_test1)
# y_pred=svm.predict(X_test1)
# 计算预测结果的准确率 1
count=0
#展平用于计算准确度 1
# y_pred=y_pred.ravel()
# y_test=y_test.ravel()
# for j in range(len(y_pred)):
#     if(y_pred[j]==y_test[j]):
#         count+=1

```

```
# acc=count/len(y_pred1)  ←  
←  
accuracy = accuracy_score(y_test1, y_pred1)←  
print('Accuracy: %.2f' % accuracy)#就是准确度 1←  
# print(acc1)←  
←  
←  
#数据标准化 消除量纲产生的问题 1←  
scaler = StandardScaler()←  
X = scaler.fit_transform(df5[features])#预测所有人的 mRS←  
all_predict=grid_search.predict(X)←  
←
```


附录七：第三问 b 题部分代码

```
#数据合并↵
#数据预处理↵
#得到首次的所有影像结果（位置，灰度，形态）及其体积↵
df1 = pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据 1/E3b/t1.xlsx')↵
df2= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据 1/E3b/t2 - 副本.xlsx')↵
df31= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据 1/E3b/t3 水肿影像.xlsx')↵
df32= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据 1/E3b/t3 血肿影像.xlsx')↵
df4 = pd.merge(df2,df31,on='首次检查流水号')↵
df5= pd.merge(df4,df32,on='首次检查流水号')↵
df5.to_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/merge1.xlsx')↵
↵
#merge2↵
#随访 1↵
df2= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t2.xlsx')↵
df31= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 水肿影像.xlsx')↵
df32= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 血肿影像.xlsx')↵
df4 = pd.merge(df2,df31,on='随访 1 流水号')↵
df5= pd.merge(df4,df32,on='随访 1 流水号')↵
↵
#merged8 为影像形状和灰度对应的大表↵
df5.to_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/merge2.xlsx')↵
↵
#merge2↵
#随访 2↵
df2= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t2.xlsx')↵
df31= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 水肿影像.xlsx')↵
df32= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 血肿影像.xlsx')↵
df4 = pd.merge(df2,df31,on='随访 2 流水号')↵
df5= pd.merge(df4,df32,on='随访 2 流水号')↵
↵
df5.to_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/merge3.xlsx')↵
↵
#merge3↵
#随访 3↵
df2= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t2.xlsx')↵
df31= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 水肿影像.xlsx')↵
df32= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 血肿影像.xlsx')↵
df4 = pd.merge(df2,df31,on='随访 3 流水号')↵
df5= pd.merge(df4,df32,on='随访 3 流水号')↵
↵
df5.to_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/merge4.xlsx')↵
```

```

#merge4
#随访 4
df2= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t2.xlsx')
df31= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 水肿影像.xlsx')
df32= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/t3 血肿影像.xlsx')
df4 = pd.merge(df2,df31,on='随访 4 流水号')
df5= pd.merge(df4,df32,on='随访 4 流水号')

df5.to_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/merge5.xlsx')

#通过 ID 合并所有表
df1= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/灰度形状特征对应的大表/merge1.xlsx')
df2= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/灰度形状特征对应的大表/merge2.xlsx')
df3=pd.merge(df1,df2,on='ID',how='left')

df4= pd.read_excel('D:/数学建模/实战/E 题/竞赛发布数据/E3b/灰度形状特征对应的大表/merge3.xlsx')
df5=pd.merge(df3,df4,on='ID',how='left')

#数据处理
df8=df8.fillna(0)#处理缺失值
#处理性别, '男', 1, '女', 0
df8['性别'] = df8['性别'].replace('男', 1)
df8['性别'] = df8['性别'].replace('女', 0)
df8 = df8.drop('血压', axis=1)#去除非数据的血压

df7=df8[:100]#前 100 名患者

x=df7.iloc[:,2:279]#特征列
y=df7.iloc[:,279]#目标列

'''
随机森林分类
'''

# 将数据集划分为训练集和测试集
X_train1, X_test1, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)

```

```

←
#数据标准化 消除量纲产生的问题←
Scaler1 = StandardScaler()←
X_train1 = scaler1.fit_transform(X_train)←
X_test1 = scaler.transform(X_test)←
←
# 创建一个随机森林分类器对象←
rf = RandomForestClassifier(n_estimators=1000, random_state=42)#n=500:0.4    1000:0.3
100:0.35←
←
# 使用训练集对模型进行拟合←
rf.fit(X_train, y_train)#开始训练←
←
# 使用测试集进行预测←
y_pred = rf.predict(X_test)#1 预测←
←
# 计算预测结果的准确率←
accuracy = accuracy_score(y_test, y_pred)←
←
print("Accuracy:", accuracy)←
←
←
←
←
←
#数据标准化 消除量纲产生的问题←
scaler = StandardScaler()←
X = scaler.fit_transform(df8.iloc[:,2:279])#预测所有人的 mRS←
all_predict=rf.predict(X)←
←
#看一下预测的对应←
df8.ID.values.reshape(-1,1)←
all_predict.reshape(-1,1)←
←
←

```